

Politechnika Warszawska

W Y D Z I A Ł M A T E M A T Y K I
I N A U K I N F O R M A C Y J N Y C H



Praca dyplomowa magisterska

na kierunku Informatyka i Systemy Informacyjne
w specjalności Projektowanie Systemów CAD/CAM

Identyfikacja dźwięku w przestrzeni samogłosek w czasie rzeczywistym

Szymon Kuś

Numer albumu 307415

promotor

dr inż. Janusz Rafałko

WARSZAWA 2025

Streszczenie

Identyfikacja dźwięku w przestrzeni samogłosek w czasie rzeczywistym

Ważnym problemem w nabywaniu języków obcych jest nauka poprawnej wymowy i fonologii. Rozróżnianie samogłosek jest kluczowe w przypadku takich języków jak angielski, gdzie jest ich wiele i są trudne do odróżnienia dla Polaków. Charakterystyczne dla nich częstotliwości — formanty — są powiązane z położeniem języka w jamie ustnej. Pozwalają one jednoznacznie identyfikować samogłoski wielu języków.

Praca przedstawia aplikację webową *Samogłoskop*, która wydobywa formanty samogłosek na podstawie danych z mikrofonu w czasie rzeczywistym. Wizualizuje je ona na wykresie reprezentującym przestrzeń samogłosek. Stworzona została w oparciu o algorytm Burga dostępny w popularnym programie do analizy mowy *Praat*. Aplikacja ma na celu pomoc w nauce wymowy samogłosek General American przez osoby polskojęzyczne, a potencjalnie można ją rozszerzyć do innych języków. *Samogłoskop* przeprowadza kalibrację do wymowy użytkownika. Zastosowana została normalizacja Lobanova, która neutralizuje różnice w rozmiarach aparatu głosowego różnych osób. Zawarte zostały modelowe dane oparte na badaniu Peterson & Barney [33] oraz nagrania przemówień polityków. Aplikacja automatyzuje proces badań wraz z wykonywaniem pre- i post-testów angielskiej wymowy.

Przeprowadzone zostały badania w trzech etapach, z czego pierwsze dwa przyniosły głównie informacje na temat odczuć użytkowników i najważniejszych błędów, lecz nie uzyskano wyników statystycznie istotnych. W trzecim etapie badania, w którym uczestniczyło 14 osób, zmierzone formanty samogłosek przed i po korzystaniu z aplikacji przez 6 dni wykazały znaczącą poprawę w wymowie w grupie badawczej, przy braku statystycznie istotnych różnic w grupie kontrolnej. Trafność samogłosek mierzona była przy użyciu odległości Mahalanobisa od wzorca. Zauważona poprawa była wyższa niż w podobnym badaniu przeprowadzonym ze studentami Uniwersytetu Stanu Iowa [35].

Słowa kluczowe: samogłoski, wizualizacja mowy, komputerowo wspomagana nauka wymowy, formanty, przestrzeń samogłosek, normalizacja Lobanova

Abstract

Real-time sound identification in vowel space

An important issue in foreign language acquisition is learning correct pronunciation and phonology. Distinguishing vowels is crucial in languages like English that have large vowel inventories which make them difficult to discern for Polish speakers. One can unambiguously identify vowels of many languages by their characteristic frequencies — formants — which are related to the position of the tongue in the mouth.

This thesis describes a web application named *Samogłoskop*, which was developed as part of this project. It extracts vowel formants from microphone data in real time, and visualizes them on a plot representing the vowel space. The program uses the Burg algorithm available in the popular speech analysis software *Praat*. The application aims to assist Polish speakers in learning General American vowel pronunciation, though it can potentially be extended to other languages. *Samogłoskop* calibrates to the user's voice characteristics. In order to neutralize the differences in vocal tract size between speakers, Lobanov normalization was applied. Model data based on the Peterson & Barney study [33] and recordings of political speeches were included. The application automates the research process, including pre- and post-tests of English pronunciation.

A series of three studies were conducted, with the first two primarily providing information about user experience and the most prominent errors, but no statistically significant results were obtained. The third study, which involved 14 participants, measured vowel formants before and after using the application for 6 days. The formant measurements showed a significant improvement in the experimental group, while no statistically significant differences were observed in the control group. Vowel accuracy was measured using Mahalanobis distance from model data. The observed improvement was greater than in a similar study conducted with students at Iowa State University [35].

Keywords: vowels, speech visualization, computer-assisted pronunciation training, formants, vowel space, Lobanov normalization

Spis treści

1. Wstęp	9
1.1. Zapis fonetyczny	10
1.2. Przestrzeń samogłosek	10
1.2.1. Monoftongi i dyftongi	11
1.2.2. Inne cechy samogłosek	12
1.3. Formanty	13
1.3.1. Model źródło-filtr	13
1.3.2. Kontekst fonetyczny	15
1.3.3. Rola aplikacji	16
2. Przegląd literatury	18
2.1. <i>Praat</i>	19
2.2. Rozpoznawanie samogłosek w czasie rzeczywistym	19
2.2.1. Rozwiązania komercyjne	21
2.3. Normalizacja	22
2.4. Rozwiązania dla dużych zbiorów danych	23
2.5. Inne rozwiązania	24
3. Opis aplikacji	25
3.1. Działanie aplikacji	26
3.1.1. Kalibracja	27
3.1.2. Sprawdzanie angielskiej wymowy	29
3.1.3. Widok ćwiczenia	31
3.1.4. Ustawienia	35
3.1.5. Widok mobilny	35
3.2. Wybrane aspekty implementacji	35
3.2.1. Ekstrakcja formantów	36
3.2.2. Wybór samogłosek	38
3.2.3. Normalizacja	39

3.2.4. Automatyzacja badań	39
3.3. Dane w aplikacji	40
3.3.1. Modelowe samogłoski angielskie	40
3.3.2. Nagrania polityków	41
3.3.3. Dane użytkownika	43
3.4. Wersje	44
4. Projekt badania	46
4.1. Zbieranie danych	47
4.2. Dobór uczestników	48
4.3. Przebieg badania	48
5. Otrzymane wyniki	50
5.1. Wyniki pierwszych dwóch etapów	55
5.1.1. Trafność samogłosek	57
5.1.2. Analiza jakościowa	58
5.1.3. Dyskusja	61
5.2. Wyniki trzeciego etapu	62
5.2.1. Trafność samogłosek	63
5.2.2. Dyskusja	68
6. Podsumowanie	70
6.1. Porównanie z badaniem aplikacji <i>Vowel Viewer</i>	70
6.2. Dalszy rozwój	73

1. Wstęp

Jednym z ważnych aspektów nauki języka obcego jest nauka wymowy. Każdy język ma swój własny system organizacji dźwięków, nazywany **fonologią**, który przejawia się jego indywidualnym brzmieniem. Jednocześnie zrozumienie fonologii języka obcego zwykle nie przychodzi tak intuicyjnie, jak w przypadku języka ojczystego. Niestety ten aspekt jest często zaniedbywany w nauce języków [7]. Z pomocą w łamaniu barier komunikacyjnych przychodzi postępująca informatyzacja, która w ostatnich latach zyskała na znaczeniu. W szczególności, w kontekście nauki wymowy, pomaga rozwój technologii syntezy i rozpoznawania mowy.

Fonologię można samą w sobie podzielić na wiele różnych aspektów. Jednym z nich jest zbiór fonemów, czyli najmniejszych jednostek ludzkiego języka mówionego. Ważne jest rozróżnienie między określeniem *fonem* a *głoska*. **Fonem** to abstrakcyjna jednostka, określająca zwykle całą kategorię **głosek**, które mogą być jej realizacjami. Fonemy są ściśle powiązane z danym językiem i w każdym z nich mogą one przybierać różne formy. Głoska jest z kolei konkretną, fizyczną realizacją fonemu, dla której można opisać ułożenie aparatu mowy i charakterystykę fali dźwiękowej.

Słowo *samogłoska* może być używane w obydwu znaczeniach. Jeśli to rozróżnienie będzie istotne, będę używał określenia *samogłoskowy fonem* dla fonemu i *samogłoskowy dźwięk* dla głoski. Samogłoski, w przeciwieństwie do spółgłosek, wyróżniają się swobodnym przepływem strumienia powietrza przez aparat mowy. Z fali dźwiękowej każdej samogłoski można wydobyć charakterystyczne częstotliwości, nazywane formantami, które pozwalają ją jednoznacznie zidentyfikować.

W niniejszej pracy przedstawiono aplikację webową o nazwie *Samogłoskop*, którą zbudowano w oparciu o istniejące rozwiązania. Rozpoznaje ona formanty samogłosek i przedstawia je wizualnie w abstrakcyjnej przestrzeni samogłosek. *Samogłoskop* ma na celu pomagać w nauce angielskich samogłosek przez Polaków. Przedstawione rozwiązanie można potencjalnie rozszerzyć dla wielu innych kombinacji języka ojczystego i języka obcego.

Przeprowadzono badania z udziałem ludzi, które miały na celu sprawdzenie, czy korzystanie z przygotowanej aplikacji może pomóc w nauce wymowy amerykańskich samogłoskowych fonemów osobom, dla których ojczystym językiem jest polski. W ostatnim etapie tych badań

uczestnicy korzystali z aplikacji na przestrzeni dwóch tygodni. Dokładny opis badań i ich wyników znajduje się w końcowych rozdziałach tej pracy.

1.1. Zapis fonetyczny

Aby ściśle określać wymowę, ta praca korzysta z Międzynarodowego alfabetu fonetycznego (ang. *International Phonetic Alphabet*, IPA) [2]. Jest to system, który pozwala na jednoznaczne przedstawienie każdego dźwięku w dowolnym języku.


W związku z rozróżnieniem głosek od fonemów, wymowę można zapisywać na dwa różne sposoby. Transkrypcję fonetyczną, dokładnie opisującą głoski, umieszcza się w nawiasach kwadratowych [], natomiast transkrypcję fonologiczną, opisującą fonemy, umieszcza się w ukośnikach / /. Nawiasy ostre < > stosuje się do zapisu ortograficznego. Dla przykładu, w języku polskim litera <n> reprezentuje fonem /n/. Jest on realizowany zwykle zębowo [n̪], jak w słowie *pan* [pän̪], ale może być realizowany też miękkopodniebiennie [ɲ], jak w słowie *bank* [bän̪k]. W tym przypadku /n/ jest fonemem, a [n̪] i [ɲ] są głoskami realizującymi ten fonem.

Zwykle mówcy nie są świadomi różnych realizacji danego fonemu w swoim języku ojczystym i uznają je za ten sam dźwięk. Dlatego też osoby anglojęzyczne uczące się języka polskiego nie są w stanie odróżnić dźwięku <ć> /t͡ɕ/ od <cz> /t͡ʂ/ i klasyfikują je oba zgodnie ze swoim systemem fonologicznym jako jeden fonem <ch>/t͡ɕ/. Podobnie, osoby polskojęzyczne uczące się języka angielskiego często mają problem z odróżnieniem dźwięków /i/ (jak w słowie *sheep*) i /ɪ/ (jak w słowie *ship*), które są dwoma różnymi fonemami w języku angielskim, ale mogą brzmieć identycznie dla polskiego ucha. Te rozbieżności są główną motywacją powstania *Sa-mogłoskopu*, który wizualizuje różnice między samogłoskowymi fonemami w języku angielskim i polskim.

1.2. Przestrzeń samogłosek

Językoznawcy już ponad sto lat temu zauważyli, że samogłoski można umieścić na dwuwymiarowej płaszczyźnie [8]. Daniel Jones wykazał, że można je rozpoznać w zależności od położenia języka. Zdefiniował on cztery samogłoski kardynalne, odpowiadające jego najbardziej ekstremalnym pozycjom. Przestrzeń samogłosek zwykło się przedstawiać w formie trapezu, którego wierzchołki reprezentują samogłoski kardynalne, jak to widać na Rysunku 1.1. Czerwonymi kropkami oznaczono najczęstsze realizacje polskich fonemów. Oś pionowa odpo-

1.2. PRZESTRZEŃ SAMOGŁOSEK



Rysunek 1.1: Trapezowa reprezentacja przestrzeni samogłosek z zaznaczonymi polskimi fonemami

wiada wysokości samogłoski. Te **otwarte** umieszcza się na dole (język znajduje się jak najdalej od podniebienia), a **przymknięte** na górze (język znajduje się blisko podniebienia). W samym środku znajdują się samogłoski **średnie**. Oś pozioma koreluje z wysunięciem poziomym języka. Na prawej krawędzi trapezu kreśli się samogłoski **tylne** (język maksymalnie schowany), a na lewej **przednie** (język jak najbardziej wysunięty). Samogłoski pośrednie w tej osi określane są jako **środkowe** [23].

1.2.1. Monoftongi i dyftongi

Samogłoski, które można umiejscowić w jednym konkretnym miejscu w opisanej przestrzeni, nazywane są **monoftongami** i są najczęściej spotykane w językach naturalnych. **Dyftongi** są z kolei takimi dźwiękami, dla których położenie w przestrzeni samogłosek gładko przechodzi w czasie z jednego położenia do drugiego. Zapisuje się je jak sekwencję dwóch samogłosek, reprezentujących początek i koniec. Mogą one brzmieć jak dwie osobne głoski, ale należy pamiętać, że jest to jeden dźwięk, lecz o zmiennej charakterystyce. Dla przykładu, pierwszy dźwięk w słowie *automat* można zapisać jako [äu], który jest dyftongiem przechodzącym od samogłoski otwartej [ä] do przymkniętej [u].

Występują też **tryftongi**, czyli dźwięki gładko przechodzące od jednej samogłoski, przez drugą, do trzeciej. Przykładem tryftongu może być [auə], czasami analizowany jako odrębny fonem, wymawiany przez niektórych brytyjskich mówców w angielskim słowie *flour*. Teoretycznie można wymawiać dźwięki przechodzące przez dowolną liczbę punktów w przestrzeni samogłosek, choć raczej nie spotyka się samogłoskowych fonemów o bardziej skomplikowanej

strukturze.

Każdą realizację monoftongów, dyftongów, jak i tryftongów można dokładniej opisać gładką funkcją zależną od czasu. Inaczej mówiąc, każdy taki dźwięk jest reprezentowany przez pewną krzywą w przestrzeni samogłosek, parametryzowaną czasem. Można sobie wyobrazić, że w przypadku monoftongów jest to funkcja stała, więc krzywa redukuje się do punktu. W przybliżeniu, dyftong wtedy można opisać odcinkiem, a tryftong krzywą zbliżoną do łamanej złożonej z dwóch odcinków.

W rzeczywistości jednak nawet monoftongi mogą mieć zmienną pozycję w przestrzeni samogłoskowej. Dla języka polskiego, zmiana ta jest pomijalna, lecz w przypadku języka angielskiego jest ona niewielka, ale mierzalna i systematyczna w obrębie danego dialektu. Zmiany położenia w przestrzeni samogłosek w czasie często mają nawet większe znaczenie niż samo położenie przy rozpoznawaniu samogłosek przez anglojęzycznych mówców [28]. Fenomen ten nazwany został **Vowel Inherent Spectral Change** (VISC) [31]. W związku z tym, *wszystkie* samogłoski języka angielskiego mogą lepiej być opisane jako krzywe, a nie punkty w przestrzeni samogłoskowej. W przypadku *Samogłoskopu* zdecydowano się na uproszczenie i nie uwzględniono tego zjawiska, zwłaszcza że skupiono się jedynie na monoftongach. W przyszłości można by jednak rozważyć dodanie tej funkcjonalności.

1.2.2. Inne cechy samogłosek

Niezależnie od położenia języka w jamie ustnej, samogłoski można też dzielić na **zaokrąglone** i **niezaokrąglone**. Różnią się one od siebie ułożeniem warg, które w przypadku tych niezaokrąglonych jest bardziej neutralne, rozwarte. W większości języków cecha ta nie jest istotna i zwykle samogłoski tylne mają tendencję do bycia zaokrąglonymi, jak polskie ⟨o⟩ /ɔ/ i ⟨u⟩ /u/, a te przednie na odwrót [36]. Są jednak języki, takie jak niemiecki, gdzie /i/ (tak, jak polskie ⟨i⟩) i ⟨ü⟩ /y/ (zaokrąglony odpowiednik polskiego ⟨i⟩) są osobnymi fonemami [30]. W języku polskim nie ma samogłoskowych fonemów, które różniłyby się jedynie zaokrągleniem warg.

W niektórych językach ważny jest też iloczyn, czyli długość samogłoski. Dla przykładu, w języku japońskim ほど /hodo/ “stopień” kończy się **krótką** samogłoską /o/, natomiast ほう /hodo:/ “chodnik” kończy się **długą** samogłoską /o:/ [2, s. 117–119].

Wymowie samogłosek zwykle towarzyszy blokada przepływu powietrza do jamy nosowej. Samogłoski takie nazywa się **ustnymi**, w odróżnieniu od **nosowych**, przy których opuszcza się podniebienie miękkie, co pozwala powietrzu przepływać zarówno przez usta, jak i nos. W języku polskim występują one marginalnie, zwykle wymawiane bez nosowości lub jako sekwencja

1.3. FORMANTY

samogłoski ustnej i spółgłoski nosowej. Dla przykładu słowo *tępy* wymawia się najczęściej jako /tɛmpɐ/, mimo że zapis sugerowałby rzadko spotykaną wymowę /tẽpɐ/.

Przeważająca większość samogłosek jest **dźwięczna**, tzn. wytwarzana przy pomocy drgań strun głosowych. Niekiedy występujące samogłoski **bezdźwięczne** zwykle nie stanowią odrębnych fonemów, a są jedynie realizacjami ich dźwięcznych odpowiedników. Dla przykładu, japońskie słowo です /desu/, zwykle wymawiane jest jako [dɛsu], gdzie okrąg pod symbolem samogłoski symbolizuje ubezdźwięcznienie. W języku polskim wszystkie samogłoski są dźwięczne.

1.3. Formanty



Przestrzeń samogłosek można zdefiniować również nie przy pomocy położenia języka, ale charakterystycznych częstotliwości, nazywanych formantami. Zauważono to już w XX. wieku [8]. Na spektrogramie dźwięku dostrzec można wyraźne ciemne pasma, gdzie koncentruje się energia. Przedstawiają one formanty (w kolejności rosnącej częstotliwości: F_1 , F_2 , F_3 , ...). Umieszczenie samogłosek na wykresie F_1 - F_2 daje bardzo podobny rysunek do trapezu przedstawionego przez Jonesa, jak można to zobaczyć na Rysunku 1.2. F_1 jest odwrotnie skorelowane z wysokością samogłoski. Na podobnej zasadzie, wysokie wartości F_2 odpowiadają samogłoskom przednim, a niskie — samogłoskom tylnym. Dzięki temu można oderwać definicje poszczególnych samogłosek od położenia aparatu mowy i operować jedynie na fali dźwiękowej.

Samogłoski zaokrąglone mają wartość F_2 niższą od ich niezaokrąglonych odpowiedników, co może wyjaśniać tendencję języków do zaokrąglania samogłosek tylnych, gdyż w ten sposób podkreślają różnice między tymi przednimi. F_3 i F_4 również odgrywają pewną rolę w rozróżnianiu samogłosek, ale jest ona bardziej złożona. Jednakowoż niewiele języków ma parę fonemów samogłoskowych o bardzo podobnych wartościach F_1 i F_2 , różniących się od siebie tylko wyższymi formantami.

Częstotliwość podstawowa (F_0), mimo podobnego oznaczenia, sama w sobie nie jest formantem i reprezentuje wysokość głosu. Ważna jest w przypadku analizy śpiewu. Ma też kluczowe znaczenie w przypadku języków tonalnych, takich jak mandaryński, w językach nietonalnych pełni rolę drugorzędną i nie rozróżnia samogłoskowych fonemów.

1.3.1. Model źródło-filtr

Produkcję mowy można analizować w uproszczony sposób przy pomocy modelu źródło-filtr. W przypadku samogłosek dźwięcznych, jako źródło uznajemy drgania strun głosowych, a jako



Rysunek 1.2: U góry: spektrogram samogłoski /æ/ w angielskim słowie *and* wypowiedzianym przez Donalda Trumpa z zaznaczonymi pierwszymi dwoma formantami. U dołu: Wartości F_1 i F_2 z powyższego słowa przedstawione razem z pomiarami innych samogłosek tego samego mówcy.

1.3. FORMANTY

filtr — aparat mowy. Aparat mowy sam w sobie jest złożonym filtrem, który możemy podzielić na jamę gardłową i jamę ustną. W przypadku samogłosek nosowych równolegle do jamy ustnej włącza się również jama nosowa, natomiast w przypadku samogłosek ustnych można ją pominąć. Najbardziej użyteczne jest spojrzenie na obwiednie widmowe, które można otrzymać z transformaty Fouriera. Spektrum pochodzące ze strun głosowych jest dość proste i opisuje nutę głosu i jej harmoniczne, więc wykres widma dźwięku można w przybliżeniu opisać przez malejące słupki oddzielone od siebie w częstotliwości co F_0 . Każdy z filtrów można opisać przez jego transmitancję widmową, która może być dość skomplikowaną funkcją. Z sygnału wyjściowego można wydobyć częstotliwości rezonansowe tych filtrów poprzez znalezienie maksimum obwiedni spektrum dźwięku samogłoski. Zatem formanty są częstotliwościami rezonansowymi aparatu mowy, które naturalnie zmieniają się wraz ze zmianą kształtu komory, jaką tworzą [11].

W jeszcze większym uproszczeniu, można potraktować gardło i jamę ustną jako serię dwóch połączonych ze sobą piszczałek, których długość zmienia się wraz z położeniem języka. Można je potraktować więc jako proste filtry pasmowoprzepustowe. Wysokość języka wpływa na długość gardła, a tym samym na jego częstotliwość rezonansową, F_1 . Z racji, że gardło jest dłuższe od jamy ustnej, to ono jest powiązane z najniższym formantem. Podobnie cofanie się języka wydłuża jamę ustną, zmniejszając jej częstotliwość rezonansową, równą F_2 i vice versa — wysuwanie języka ją zwiększa. Dlatego też zaokrąglanie warg powoduje dodatkowe obniżenie F_2 , gdyż złożone w kształt rurki wargi tworzą niejako przedłużenie jamy ustnej. Oczywiście, ten najprostszy model nie tłumaczy istnienia wyższych formantów, które powstają dzięki dodatkowym rezonansom w złożonym kształcie jamy ustnej. Ten model zwraca jednak uwagę na sytuację, która może utrudnić rozpoznawanie samogłosek. Co, jeżeli jama ustna będzie miała podobną długość, a tym samym częstotliwość rezonansową, do gardła? Może się tak zdarzyć w przypadku samogłosek tylnych, wtedy $F_1 \approx F_2$. W tym przypadku dwa pierwsze formanty zlewają się na spektrum ze sobą i w obwiedni widmowej będzie widoczne tylko jedno maksimum. Jest to jedna z problematycznych sytuacji, którą algorytmy ekstrakcji formantów muszą brać pod uwagę.

1.3.2. Kontekst fonetyczny


Formanty zależą nie tylko od czasu (jak w przypadku dyftongów, gdzie ruch w przestrzeni samogłosek odpowiada ruchowi formantów) i fonemu, ale też od jego kontekstu fonetycznego, czyli otaczających go dźwięków. Dla przykładu, /u/ wypowiedziane w sylabie /tu/ będzie miało inną charakterystykę formantów niż w sylabie /pu/, a jeszcze inną w izolacji po prostu jako /u/. Podobnie, spółgłoski następujące po samogłosce również mają wpływ na formanty. W dużej

mierze można to tłumaczyć tym, że aparat mowy musi przemieścić się z jednego położenia do drugiego w miarę wypowiedzi i przechodzenia od jednego fonemu do drugiego, więc cechy spółgłoski niejako “przelewają” się na samogłoskę. Jak pokazują badania, takie jak [18] te efekty są znaczące i odgrywają dużą rolę w rozpoznawaniu samogłosek, zarówno syntetycznej mowy przez ludzi, jak i naturalnego języka przez komputery. Największy efekt mają spółgłoski dźwięczne, takie jak angielskie /t/ poprzedzające zaokrąglone samogłoski, takie jak /u/. Zwiększa to F_2 w porównaniu do innych kontekstów.

W *Samogłoskopie*, celem uproszczenia implementacji, ograniczono użytkownika do wypowiedziania izolowanych samogłosek. Można natomiast w przyszłości program rozszerzyć w oparciu o powyższe dane.

1.3.3. Rola aplikacji

Zgodnie z powyższym, można skonceptualizować proces przetwarzania samogłosek, jak na Rysunku 1.3. Niech zostanie rozważona sytuacja, w której dwie osoby komunikują się ze sobą w pewnym języku naturalnym. W trakcie wypowiedziania słowa, mózg mówcy, bez jego świadomości, znajduje odpowiednią samogłoskę i wysyła sygnały do odpowiednich części aparatu głosowego, by wyprodukować falę dźwiękową. Gdy ta fala dźwiękowa dotrze do słuchacza, już w jego uchu wewnętrznym jest interpretowana jako widmo i przesyłana do mózgu. Najprawdopodobniej w tym momencie mózg słuchacza zauważa w tym widmie wiele charakterystycznych cech, w tym formanty, które są kluczowe do zrozumienia głoski i jej klasyfikacji jako odpowiedniego fonemu. Badanie z 2023 roku sugeruje, że właśnie w taki sposób w uproszczeniu działa ośrodek słuchu w ludzkim mózgu, choć jest to w rzeczywistości bardziej złożony proces [32].



Rysunek 1.3: Proces przetwarzania samogłosek

Jak jest to oznaczone strzałkami na górnej części rysunku, aplikacje w dziedzinie syntezy

1.3. FORMANTY

mowy (ang. Speech Synthesis) przechodzą bezpośrednio od samogłoski, a zazwyczaj jeszcze wcześniej, od jej tekstowej reprezentacji, do fali dźwiękowej. Podobnie aplikacje zajmujące się rozpoznawaniem mowy (ang. Speech Recognition) przechodzą bezpośrednio w drugą stronę. Proces ten może zawierać algorytmiczną analizę formantów wyrażoną jawnie lub może pozostawiać ten aspekt uczeniu maszynowemu. Z reguły jednak narzędzia te nie pokazują użytkownikowi informacji o formantach, a zwłaszcza te działające w czasie rzeczywistym.

Stworzona w ramach tej pracy aplikacja *Samogłoskop* ma za zadanie zatrzymać się na etapie rozpoznawania formantów i wykorzystać te informacje w kontekście dydaktycznym. Dzięki temu użytkownik sam może wyciągnąć wnioski o przestrzeni samogłosek i różnicach między językiem ojczystym a obcym. Aplikacja ta przyjmuje dane z mikrofonu w czasie rzeczywistym, w trakcie mówienia samogłoski. Jednocześnie z minimalnym opóźnieniem wyświetlają się na ekranie formanty dźwięku i ich zmiana na dwuwymiarowym wykresie.

2. Przegląd literatury

Pomysł automatycznej ekstrakcji formantów wcale nie jest nowy i sięga lat 50. ubiegłego wieku. Wtedy został opracowany pierwszy program komputerowy, który z 93-procentową skutecznością był w stanie identyfikować samogłoski języka angielskiego w słowach postaci /bVt/, gdzie V oznacza samogłoskę. Osiągnięto to poprzez wydobywanie wartości F_1 i F_2 [14].

W roku 1970 przedstawiono inny algorytm pozwalający dokładniej wyznaczyć obwiednię widmową korzystając z analizy cepstrum. Program ten — przy użyciu ograniczeń na wartości formantów — pozwolił na wykrywanie sytuacji, gdy dwa formanty są blisko siebie. Autorzy nie użyli go jednak do rozpoznawania samogłosek, lecz w połączeniu z synteizatorem mowy, który generował dźwięk jedynie na podstawie wyodrębnionych formantów. Udało im się w ten sposób zreprodukować krótkie zdania złożone z ograniczonego zbioru fonemów języka angielskiego, w tym samogłosek [38].

W XXI. wieku cały czas widać rozwój w tej dziedzinie. Artykuł napisany przez Aníbalą Ferreirę z Uniwersytetu Porto pod tytułem *Real-time recognition of isolated vowels* zwraca uwagę na problem z wyznaczaniem formantów w przypadku dużej wartości F_0 , nie tylko w przypadku śpiewania bardzo wysokich nut, ale też naturalnie wysokiego głosu kobiet i dzieci podczas mówienia. Zaproponował on nową metodę, która nie wyznacza bezpośrednio formantów, ale polega na wydobywaniu cech z tzw. percepcyjnych grup widmowych (ang. Perceptual Spectral Clusters, PSC). Udało mu się w ten sposób uzyskać klasyfikację samogłosek wypowiedzianych przez kobiety i dzieci ze skutecznością 88%, co jest lepsze od predykcji liniowej (84%), ale gorsze od klasyfikacji opartej na analizie współczynników cepstralnych MFCC (ang. Mel-frequency cepstral coefficients), której skuteczność wyniosła 94% [12].

Twórcy innego badania zauważyli, że korzystając z analizy bayesowskiej można przeprowadzić ekstrakcję F_1 i F_2 dającą wyniki porównywalne z ręcznym oznaczaniem tych formantów przez eksperta. Bazowali oni na pakiecie oprogramowania ESPS (ang. Entropic Signal Processing System), i przetestowali na dużym zbiorze danych dwie wersje: bazową, bez żadnych modyfikacji i proponowaną probabilistyczną. Następnie przeprowadzili zadanie klasyfikacji samogłosek na powstałych danych o formantach. W podstawowym wariancie osiągnęli 90% skuteczności, a w modelu bayesowskim 97%. Przeprowadzili dla porównania również ręczne wy-

2.1. PRAAT

znaczenie formantów, dla którego klasyfikacja sprawdzała się również na poziomie 97% [10].

2.1. *Praat*

Obecnie najpopularniejszym programem do analizy mowy jest otwartoźródłowy *Praat*. Jego funkcjonalność wykracza znacznie poza wyodrębnianie formantów, ponieważ pozwala na adnotację, manipulację dźwięków, a także ich syntezę. Wbudowany język skryptowy umożliwia automatyczne przetwarzanie tysięcy nagrań, a moduł graficzny może pozwalać na tworzenie wykresów bez potrzeby przenoszenia wyników do innego programu [4].

Praat wydobywa formanty korzystając z algorytmu Burga, opartego na technice maksymalizacji entropii [16]. Można edytować jego parametry, takie jak sufit formantów. Różne parametry dają najlepsze wyniki dla różnych mówców, choć największa różnica występuje w przypadku wymienionego sufitu formantów, pomiędzy kobietami, mężczyznami i dziećmi. Metoda Burga jest przykładem algorytmu z dziedziny predykcji liniowej (ang. Linear Predictive Coding, LPC).

Jednakże *Praat* używany jest głównie przez naukowców i nie pozwala, chociażby, na wyodrębnianie formantów w czasie rzeczywistym. Jako bardzo szeroki program nie skupia się na dostępności do bardziej ogólnej grupy odbiorców. Trudno więc spodziewać się, żeby zauważalna część osób uczących się języków obcych mogła z niego skorzystać w celu poprawy wymowy.

2.2. Rozpoznawanie samogłosek w czasie rzeczywistym

Istnieje kilka prac, które skupiają się na rozpoznawaniu samogłosek w czasie rzeczywistym. Pewna portugalska badaczka we współpracy ze wspomnianym wcześniej Aníbarem Ferreira, wykorzystując współczynniki MFCC i klasyfikację bayesowską, osiągnęła 96% skuteczności w rozpoznawaniu samogłoskowych fonemów języka portugalskiego. Porównali oni 2 podejścia do mapowania MFCC na parametry dla klasyfikatora, z których najlepsza okazała się analiza wyróżników liniowych (ang. Linear Discriminant Analysis, LDA). Uwzględnienie F_0 , który zazwyczaj nie jest kojarzony z rozróżnianiem samogłosek, dało lepsze wyniki niż jego pominięcie. Następnie zaimplementowali oni te algorytmy w czasie rzeczywistym bez dużego pogorszenia skuteczności. Na koniec stworzyli wyścigową grę komputerową ze sterowaniem głosowym i zawarli w niej najlepszy klasyfikator [6].

Zdecydowanie warty wspomnienia jest program *Vowel Articulation Training Aid* (VATA). Apli-

kacja ta powstała ponad 20 lat temu i nie jest już rozwijana, ale nadal jest dostępna do pobrania dla systemu Windows. To jedyne rozwiązanie omawiane w tym podrozdziale, które jest dostępne w Internecie i uruchamia się poprawnie. Oprogramowanie to zostało stworzone z myślą o osobach z wadami słuchu i zawiera wiele minigier sterowanych głosem. Wykorzystane zostało uczenie maszynowe MLP (ang. Multi-Layer Perceptron) do rozpoznawania 10 samogłosek języka angielskiego. Mimo, że nie wydobywa bezpośrednio formantów, aplikacja zawiera widok przestrzeni samogłosek, który ocenia pozycję dźwięku na podstawie odpowiedzi sieci neuronowej [44]. Własne testowanie wskazało, że program działa dobrze, ale nie radzi sobie z ocenianiem pozycji samogłosek, które nie pasują do fonemów języka angielskiego, np. polskie ⟨y⟩/ə/.

Aplikacja *Vowel Worm* została również stworzona z myślą o wizualizacji dźwięku w przestrzeni samogłosek w czasie rzeczywistym. Nie zawiera ona wbudowanego klasyfikatora, chociaż autorzy wspominają, że jest to trywialne zadanie. Program ten nie korzysta z wyodrębniania formantów, ale próbuje ocenić otwartość/zamknięcie oraz wysunięcie/cofnięcie samogłoski przy pomocy regresji liniowej korzystającej z współczynników MFCC. Algorytm został wytrenowany na korpusie danych mówionych i, co najważniejsze, został przystosowany do rozpoznawania śpiewanych samogłosek. Są dostępne filmy wideo przedstawiające działanie *Vowel Wormu* na przykładowych utworach muzycznych. Nagrania pokazują w dużej mierze wizualizację zgodną ze śpiewanymi głoskami, ale są też zauważalne rozbieżności. Autorzy nie przeprowadzili jednak analizy rozpoznawania położenia w przestrzeni samogłosek dla większego zbioru danych [15]. W 2014 roku powstała wersja dostępna online, choć nie jest już regularnie aktualizowana. Testy własne wskazują, że aplikacja wymaga pracy. Potrzeba było wielu prób, żeby w ogóle uruchomić wizualizację. Zaobserwowano też, że algorytm wciąż nie radzi sobie z wysokimi dźwiękami i, dla przykładu, umieszcza wysoko śpiewane /a/ w tym samym rejonie, co mówione /u/.

Językoznawczyni Ivana Rehman z Uniwersytetu Stanu Iowa w swojej rozprawie doktorskiej zatytułowanej *Real-time formant extraction for second language vowel production training* przedstawiła narzędzie *Vowel Viewer* o bardzo podobnej funkcjonalności do *Vowel Wormu*. Zaprogramowane ono zostało w języku JavaScript i komunikuje się z backendem opartym o pythonową bibliotekę *parselmouth*, która jest w zasadzie interfejsem do wcześniej wspomnianego *Praata* [20]. Oprócz wizualizacji formantów w czasie rzeczywistym, program zawierał nagrania słów wypowiedzianych przez ojczystych mówców języka angielskiego. Rehman skupiła się głównie na zaprojektowaniu solidnego, dwuetapowego badania z osobami, dla których angielski nie jest językiem ojczystym. Pierwszy etap badał mniejszą grupę i miał na celu poinform-

mować, co należy dopracować w aplikacji i procedurze badawczej w drugim etapie. Badanie miało na celu sprawdzenie, na ile wymowa samogłosek poprawia się po dłuższym korzystaniu z programu. W drugim etapie wzięło udział 19 osób, które korzystały z aplikacji w dziewięciu 30-minutowych sesjach na przestrzeni trzech tygodni. Uczestnicy byli podzieleni na grupę kontrolną i badawczą. Wszyscy uczestnicy wzięli udział w pre- i post-teście, a grupa badawcza też w trzecim, opóźnionym post-teście. Test zawierał czytanie serii słów, a także narrację filmu wideo. Wszystkie wypowiedzi zostały później przeanalizowane i na podstawie formantów samogłosek stwierdzano odległość od modelowej wymowy. Wyniki pokazały, że grupa badawcza poprawiła się znacząco w porównaniu do grupy kontrolnej w przypadku czytanych słów, ale w przypadku narracji poprawę widać było dopiero w opóźnionym teście [35]. Autorka zaznaczyła, że narzędzie jest dostępne i zachęca do jego rozwoju, jednak nie nadmienia, gdzie znaleźć kod źródłowy i nie odpowiedziała na korespondencję mailową z zapytaniem o dostęp. Niemniej jednak, wspomniana rozprawa doktorska stanowiła główną inspirację dla projektu badania opisanego w tej pracy.

2.2.1. Rozwiązania komercyjne

Zrobiono również przegląd dostępnych aplikacji mobilnych i kursów online, które oferują ćwiczenie wymowy samogłosek z pomocą algorytmów rozpoznawania mowy. Najpopularniejszą taką aplikacją jest *Duolingo* [19], która niedawno wprowadziła sekcję ćwiczeń wymowy poszczególnych samogłosek, wraz z nagraniami audio przykładowych słów i rozpoznawaniem wymowy na urządzenia Android i iOS. Testy własne wykazały, że aplikacja nie radzi sobie dobrze z rozpoznawaniem samogłosek i wiele prób celowego wypowiadania błędnych dźwięków oznaczane było jako poprawne. Podobnie sprawdziła się aplikacja mobilna *BoldVoice* [5], która oferuje ćwiczenia wymowy wraz z filmami instruktażowymi. Twórcy powyższych aplikacji nie dzielą się informacjami na temat algorytmów, natomiast można spekulować, że oparte są one o sieci neuronowe i nie wyodrębniają formantów *explicite*.

W sklepie App Store firmy Apple można było z kolei znaleźć aplikację o nazwie *VowelViz Pro* [40], której twórcy obiecywali wizualizację wypowiadanych samogłosek w czasie rzeczywistym, a na grafikach promocyjnych można zobaczyć rysunek przestrzeni samogłosek. Aplikacja miała jednak mieszane oceny i nie jest już dostępna w App Store. Nie udało się przeprowadzić testu własnego, ze względu na brak dostępu do urządzenia z systemem iOS, który był wymagany do jej uruchomienia.

2.3. Normalizacja

Można wykazać, że formanty samogłoskowych dźwięków są systematycznie związane z ich fonemami, co pozwala je kategoryzować tylko na podstawie tych dwóch wartości. Jest to dość łatwe zadanie dla pojedynczego mówcy, jednak sprawa komplikuje się przy analizowaniu mowy wielu zróżnicowanych ojczystych użytkowników języka. Okazuje się bowiem, że przestrzeń samogłosek każdej osoby wygląda trochę inaczej. I choć dla pojedynczej osoby można wskazać konkretny obszar w przestrzeni formantów odpowiadający każdej samogłosce, to te obszary nie zawsze będą takie same dla wszystkich mówców. Dla przykładu, /u/ wypowiedziane przez kobietę może mieć wartości formantów bardziej zbliżone do /o/ wypowiedzianego przez mężczyznę. Różnice te wynikają z różnych rozmiarów aparatu głosowego, a także czynników kulturowych.

Znając natomiast wartości formantów dla wszystkich samogłosek języka, można je normalizować, dla każdego mówcy z osobna. Boris Lobanov zaproponował w 1971 roku w artykule pt. *Classification of Russian vowels spoken by different speakers* statystyczny schemat normalizacji, przedstawiony w Równaniu (2.1), który porównał z dwoma innymi metodami i wykazał, że jego propozycja ma najlepszą jakość, na przykładzie pięciu różnych mówców i samogłosek języka rosyjskiego [29]. $\overline{F}_i$ to średnia formantu F_i dla wszystkich samogłosek mówcy, a σ_i to jego odchylenie standardowe. F_i^N reprezentuje znormalizowaną postać pojedynczego pomiaru formantu F_i .

$$F_i^N = \frac{F_i - \overline{F}_i}{\sigma_i} \quad (2.1)$$

Normalizacja Lobanova osiąga dobre wyniki w przypadku porównywania różnych mówców danego języka, ale niekoniecznie sprawdza się w porównywaniu do siebie różnych języków. Rozważała to Sandra Disner w 1980 roku i pokazała w swoim artykule pt. *Evaluation of vowel normalization procedures* na przykładzie sześciu języków germańskich, że normalizacja Lobanova może nie pokazywać dobrze korespondencji między fonemami samogłosek różnych języków. Dla przykładu, fonetycy powszechnie opisują duńskie /i/ jako bardziej przymknięte niż angielskie /i/, natomiast po normalizacji Lobanova wydaje się, jakby było na odwrót. Dlatego należy brać pod uwagę opisy fonetyczne języków w przypadku porównywania ich ze sobą. Poza tym, badaczka porównywała inne metody normalizacji i zauważyła, że im lepiej dany schemat się sprawdza w obrębie jednego języka, tym bardziej zaburza on korespondencje pomiędzy językami. Co ciekawe, w wielu jednojęzykowych przypadkach metoda Nearey'ego była najlepsza, ale w jednym przypadku — języka szwedzkiego — lepiej poradziła sobie normalizacja

2.4. ROZWIĄZANIA DLA DUŻYCH ZBIORÓW DANYCH

Lobanova [9].

W przypadku wielu dialektów jednego języka natomiast, normalizacja Lobanova i Nearey'ego wydaje się być dobrym narzędziem dla neutralizowania różnic w rozmiarach aparatu mowy, jak to ma miejsce w przypadku płci, pozostawiając wciąż cenne informacje o różnicach pomiędzy odmianami języka. Pokazuje to Patti Adank w artykule zatytułowanym *A comparison of vowel normalization procedures for language variation research*, na przykładzie samogłosek języka niderlandzkiego 80 mężczyzn i 80 kobiet z różnych regionów Holandii i Flandrii [1].

Inne badanie, przeprowadzone w 2011 roku, implikuje z kolei, że normalizacja Lobanova daje znacznie lepsze wyniki niż Nearey'ego pod względem neutralizacji różnic w rozmiarach aparatu mowy. Metoda Lobanova uplasowała się na trzecim miejscu, za normalizacjami Gertsmiana i Bighama, które nie są tak powszechnie stosowane. Badanie to korzystało z danych 20 mówców języka angielskiego z Nottingham [13].

Tymczasem artykuł [24], pokazuje wyniki sugerujące, że przy rozpoznawaniu samogłosek ważniejsze od normalizacji, czy nawet uwzględniania kontekstu fonetycznego, jest wzięcie pod uwagę częstotliwości podstawowej, wyższych formantów i zmiany ich wartości w czasie. Pełna wersja wspomnianego tekstu zdaje się być jednak niedostępna.

2.4. Rozwiązania dla dużych zbiorów danych

Niektóre rozważane rozwiązania w dziedzinie ekstrakcji formantów i rozpoznawania samogłosek są naprawdę obiecujące, ale ich zamierzone zastosowanie nie leży w dydaktyce, czy nauce wymowy, ale analizy zbiorów danych na większą skalę, co może być przydatne dla socjolingwistów. Dla przykładu, 10 lat temu opracowano w pełni zautomatyzowany system ekstrakcji formantów z nagrań mowy o nazwie DARLA (ang. Dartmouth Linguistic Automaton). Przełomowe w nim jest to, że w porównaniu do poprzedniego algorytmu w programie FAVE (ang. Forced Alignment & Vowel Extraction), nie są potrzebne nawet transkrypcje nagrań. Dodano do wspomnianego systemu automatyczną transkrypcję, która, jak oceniają autorzy, nawet popełniając błędy, nie daje w dużej mierze fałszywych wyników pod względem tożsamości samogłosek. Popierają to danymi, które sugerują, że używanie ręcznej transkrypcji nie zmienia znacząco wyników analizy formantów w porównaniu z DARLA, choć wymaga więcej pracy. System zdaje się być zamkniętoźródłowy, choć jego twórcy zachęcają do przesyłania im zbiorów danych, które mogliby wykorzystać do dalszego rozwoju [34].

Propozycją prawdziwie uniwersalnego systemu jest stworzony przy użyciu Pythona i uczenia głębokiego *Allosaurus*. Przyjmuje on na wejściu sygnał dźwiękowy i bez potrzeby podania

transkrypcji przetwarza go na zapis fonetyczny. Największą zaletą tego systemu jest wielojęzkowe podejście, które pozwala z założenia na analizowanie systemu fonetycznego dowolnego języka na świecie. Wzięto pod uwagę fakt, że fonemy mogą mieć wiele różnych realizacji i przypisanie głosek do fonemów zależy od języka. W przeciwieństwie do innych systemów, dodana została dodatkowa warstwa do modelu, która najpierw próbuje zidentyfikować konkretną głoskę, a następnie w zależności od języka przypisuje jej odpowiedni fonem. Autorzy wykazali, że w porównaniu z dotychczasowymi systemami takie podejście daje o 2% lepsze wyniki w kontekście języków, które były uwzględnione w danych treningowych, a nawet o 17% w przypadku języków, których system nigdy wcześniej nie widział. Ma to więc duży potencjał dla tysięcy języków, dla których dane są ograniczone [27]. Niestety, jak doświadczonego tego w testach własnych, system nie sprawdzał się dobrze w mierze absolutnej. Przy ograniczeniu do języka polskiego popełniał często błędy. Najprawdopodobniej można by to znacznie poprawić, uwzględniając dodatkowo transkrypcje ortograficzne, jak w systemie DARLA. W przypadku ustawienia systemu na tryb uniwersalny (nie powiązany z żadnym konkretnym językiem), wyniki zdawały się być jeszcze bardziej rozbieżne, niż można by się spodziewać po profesjonalnej transkrypcji fonetycznej.

2.5. Inne rozwiązania

Chociaż ten tekst nie skupia się na samogłoskach nosowych, warta jest wspomnienia praca, która zajmuje się pomiarem nosowości na podstawie danych akustycznych. Są przesłanki, że korzystając z formantów i ich energii, można odróżniać samogłoski nosowe od ustnych. Michael Berger pokazuje to w swojej pracy magisterskiej zatytułowanej *Measurement of vowel nasalization by multi-dimensional acoustic analysis*. Zwraca uwagę on, że pojawiają się nowe, nosowe formanty, a te ustne ulegają wytłumieniu. Można nawet zauważyć, że spektrum dźwięku zmienia się stopniowo wraz ze wzrostem stopnia nosowości. Charakter tych zmian różni się znacząco w zależności od mówcy, ale można to normalizować [3].

Ciekawe podejście można zobaczyć w badaniu [41]. Zamiast wyodrębniać formanty z fali dźwiękowej, autorzy umieścili sensory w jamie ustnej uczestników. Mimo bardziej inwazyjnej metody, uzyskali skuteczność w rozpoznawaniu angielskich samogłosek w zakresie od 76 do 91%, nie lepszą od podejścia akustycznego.

3. Opis aplikacji

Samogłoskop jest aplikacją webową, napisaną w całości w języku JavaScript/TypeScript. Podobnie jak wspomniany w Podrozdziale 2.2 *Vowel Viewer*, korzysta z algorytmu znajdowania formantów z *Praata*, choć w tym przypadku cały odpowiedzialny za to kod został ręcznie sportowany z oryginalnego C++ do JavaScriptu, o czym więcej napisano w Punkcie 3.2.1. Oprócz tego polega na bibliotece D3.js do wizualizacji. Program wyposażony jest w wiele modułów, pozwala na:

- wyodrębnianie formantów i przedstawianie ich na wykresie w czasie rzeczywistym,
- pokazanie na tym samym wykresie samogłosek modelowej wymowy, a także z poprzednich nagrań użytkownika,
- wybór reprezentacji lub całkowite schowanie powyższych zbiorów danych,
- skupienie na pojedynczej samogłosce po kliknięciu na jej reprezentację,
- zobaczenie przykładowych słów z samogłoską, wraz z transkrypcją i użyciem w zdaniu,
- odsłuchanie nagrań polityków dla wybranych słów,
- kalibrację do głosu użytkownika i poziomu szumu,
- zautomatyzowanie badań, w tym losowe przydzielanie do grupy kontrolnej/badawczej oraz prowadzenie testów wymowy z zapisem formantów,
- wybór kategorii głosu (kobieta, mężczyzna, dziecko),
- zapis stanu aplikacji do pliku i wczytywanie go później,
- śledzenie czasu spędzonego na ćwiczeniu z podziałem na dni.

Aplikacja dostępna jest pod adresem <https://ogoras.github.io/samogloskop/>. Obsługuje zarówno komputery osobiste jak i urządzenia mobilne. Kod źródłowy wraz z wynikami badań można znaleźć w repozytorium GitHub: <https://github.com/ogoras/samogloskop>. Wideo przedstawiające działanie programu znajduje się pod adresem https://youtu.be/pfPSW5_UnV8.

3.1. Działanie aplikacji

Witaj w aplikacji **Samogłoskop**! Na początek obejrzyj krótki filmik instruktażowy.



Ta strona używa pamięci **localStorage**, by zapamiętywać dane o twoim głosie. Jeżeli nie wyrażasz na to zgody, korzystanie z aplikacji może być utrudnione. Twoja zgoda i inne dane będą zapamiętane, przechowywane i przetwarzane, wyłącznie na Twoim urządzeniu.

[Polityka prywatności](#)

Nie wyrażam zgody

Wyrażam zgodę

[Więcej informacji](#)

Rysunek 3.1: Zrzut ekranu po pierwszym uruchomieniu aplikacji

Wybierz kategorię, która najbardziej do Ciebie pasuje. Pamiętaj, aby kierować się charakterystyką swojego głosu, więc np. dla chłopca po mutacji najpewniej sprawdzi się opcja "mężczyzna", niezależnie od wieku.

Jestem:

kobieta

mężczyzn

dzieckiem

[Więcej informacji](#)


Rysunek 3.2: Zrzut ekranu z wyborem kategorii głosu

Przy pierwszym uruchomieniu użytkownik widzi ekran przedstawiony na Rysunku 3.1, zawierający instrukcję wideo i zgodę na przechowywanie danych. Po zaakceptowaniu wybiera **kategorię głosu** (Rysunek 3.2), od której zależy sufit formantów zadawany do algorytmu Burga. Kategorie i odpowiadające im wartości tego parametru znajdują się w Tabeli 3.1.

Tabela 3.1: Kategorie głosu i odpowiadające im sufity formantów

Kategoria głosu	Sufit formantów [Hz]
kobieta	5500
mężczyzna	5000
dziecko	8000

3.1.1. Kalibracja




Rysunek 3.3: Zrzut ekranu w trakcie kalibracji poziomów


Po wybraniu kategorii głosu użytkownik obowiązkowo przechodzi przez kalibrację, która dzieli się na dwie części: kalibrację poziomów i nagranie polskich (ojczystych) samogłosek. Podczas kalibracji poziomów użytkownik nagrywa przez 10 sekund ciszę, a następnie przez 10 sekund mówi do mikrofonu. Na Rysunku 3.3 przedstawiony jest zrzut ekranu widoku kalibracji. Uzyskane wartości są dalej używane do wykrywania, czy użytkownik mówi, czy nie. Aplikacja zakłada, że użytkownik mówi, jeśli poziom średniego natężenia dźwięku w ostatniej jednej dziesiątej sekundy przekracza lub jest równy $L_{max} - 30$ dB, gdzie L_{max} to maksymalny poziom natężenia dźwięku zarejestrowany podczas kalibracji.

Następnie *Samogłoskop* prosi użytkownika o powiedzenie polskich samogłosek w losowej kolejności. Polskie samogłoski brane pod uwagę opisane są w Punkcie 3.2.2. Każda z liter ma przypisany swój własny kolor w taki sposób, żeby sąsiednie w przestrzeni formantów samogłoski miały podobne do siebie kolory. Już w tym momencie uruchamiany jest algorytm Burga w czasie rzeczywistym i użytkownik widzi symbole samogłoski na dwuwymiarowym wykresie pojawiające się w trakcie mówienia. Osie wykresu oznaczone są chwilowo wartościami częstotliwości w Hz, jak można zobaczyć na Rysunku 3.4.

Po zebraniu wszystkich samogłosek następuje normalizacja Lobanova, która sprawia, że środek przestrzeni samogłosek użytkownika znajduje się w punkcie (0, 0), a odchylenie standardowe w obu osiach wynosi 1. Mówienie do mikrofonu wpływa na ruch czarnej kropki, która reprezentuje wygładzony pomiar aktualnych formantów. Oprócz pełnej czarnej kropki pojawiają się też mniejsze, półprzezroczyste kropki, odpowiadające pojedynczym pomiarom w kolejnych klatkach. W tym momencie aplikacja oferuje możliwość ponowienia nagrań wybranych samo-




Rysunek 3.4: Zrzut ekranu w trakcie nagrywania polskich samogłosek



Rysunek 3.5: Zrzut ekranu z zatwierdzeniem polskich samogłosek zrobiony w trakcie wymawiania [i]

3.1. DZIAŁANIE APLIKACJI

głosek. Użytkownik powinien wizualnie potwierdzić, że pomiary nie nachodzą na siebie w przestrzeni samogłosek, ewentualnie poprawić rozbieżności i zatwierdzić, kiedy uzna, że pomiary są poprawne. Zaktualizowane jednostki wraz z widokiem zatwierdzenia polskich samogłosek można zobaczyć na Rysunku 3.5.




Rysunek 3.6: Zrzuty ekranu przedstawiające kolejno centroid, chmurę punktów i elipsę dla samogłoski /i/

W tym widoku po raz pierwszy pojawia się opcja nazwana *wyborem reprezentacji*. Trzy przełączniki pozwalają na niezależne kontrolowanie trzech różnych widoków pomiarów samogłosek. Pierwszy z nich to **centroidy**, oznaczony pojedynczą literą. Są to duże symbole umieszczone w punktach odpowiadających średnim formantom. Drugi to **chmury punktów**, symbolizowany trzema literami. Są to małe symbole odpowiadające pojedynczym pomiarom w poprzednich klatkach. Ostatni to **elipsy**, rysowane w oparciu o macierz kowariancji. Elipsy te obejmują obszar niepewności zawierający 95% punktów z założeniem dwuwymiarowego rozkładu chi kwadrat. Każdy z widoków, wyodrębniony dla przykładowego nagrania samogłoski /i/, widnieje na Rysunku 3.6. Użytkownik może wybrać dowolny widok lub ich kombinację.

Z powodu błędu, wszystkie wersje aplikacji użyte w badaniach niepoprawnie rysowały elipsy, jednak dla zbiorów danych obecnych w programie różnica była bardzo niewielka, niezauważalna podczas normalnego działania aplikacji. Porównanie między niepoprawnym a poprawnym rysowaniem elips można zobaczyć na Rysunku 3.7. Z racji, że różnica nie jest na pierwszy rzut oka widoczna, znajduje się tam też obraz przedstawiający tylko ją.

3.1.2. Sprawdzanie angielskiej wymowy

Samogłoskop wspiera prowadzenie testów angielskiej wymowy w oparciu o nagrania polityków. Podobnie jak w przypadku polskich samogłosek, fonemy z wariantu General American, opisane dokładniej w Punkcie 3.2.2, są nagrywane w losowej kolejności. Dla każdej samogłoski przedstawiany jest jej zapis fonologiczny, przykładowe słowo z transkrypcją i tłumaczeniem, a także, dla szerszego kontekstu, całe wyrażenie z tłumaczeniem. Dla każdego z tych trzech



Rysunek 3.7: Zrzuty ekranu przedstawiające elipsy rysowane niepoprawnie (po lewej) i poprawnie (na środku) na przykładzie zbioru danych Peterson & Barney [33], a także odwrócony obraz różnicowy między nimi (po prawej)





[Więcej informacji](#)
 Dzisiaj ćwiczysz już: 0:11:17

Powiedz "æ", głośno i wyraźnie... Powiedz tylko "æ", a nie całe słowo!

Powtórz samogłoskę:

æ

▶

jak w słowie:

aspect /æspɛkt/

▶

aspekt

w wyrażeniu:

in every aspect

▶

w każdym aspekcie

Hillary Clinton, 1995
[źródło](#)

Rysunek 3.8: Zrzut ekranu testu angielskiej wymowy, w trakcie mówienia [æ]

3.1. DZIAŁANIE APLIKACJI

poziomów można odsłuchać fragmentu nagrania. Nagranie słowa jest wycięte z nagrania wyrażenia i podobnie nagranie samogłoski jest wycięte z nagrania słowa. Wszystkie nagrania pochodzą z przemówień Hillary Clinton i Donalda Trumpa dostępnych w domenie publicznej. Więcej o nagraniach można przeczytać w Punkcie 3.3.2.

Po zapoznaniu się z nagraniami, użytkownik włącza mikrofon i powtarza samogłoskę. W celu uproszczenia algorytmu, dodana została instrukcja, aby powiedzieć ją w izolacji. Głoskę trzeba powiedzieć co najmniej przez 39 klatek, aby program mógł dobrze wygładzić pomiary formantów. Sprawia to, że nagrania modelowe są dość krótkie, a użytkownik jest zmuszony nienaturalnie “przeciągać” je w czasie. Na Rysunku 3.8 przedstawiony jest zrzut ekranu w trakcie mówienia.

Po nagraniu każdej samogłoski, użytkownik może odsłuchać swoją próbę, ale nie może chwilowo odsłuchać ponownie polityka. Jeśli czuje, że jego podejście zgadza się z modelem, zatwierdza swoje nagranie. W przeciwnym razie może spróbować ponownie. Po zatwierdzeniu użytkownik przechodzi do kolejnej samogłoski.


Test został zaprojektowany w taki sposób, aby użytkownik — nie będąc nawet zaznajomiony z wymową amerykańską — mógł próbować naśladować usłyszany dźwięk. Kluczowy w teście jest brak dostępu do wykresu przestrzeni samogłosek, który jest zarezerwowany tylko do widoku ćwiczenia. Dzięki temu można sprawdzić, jak użytkownik radzi sobie bez pomocy wizualnej w czasie rzeczywistym.

3.1.3. Widok ćwiczenia


Najważniejszy w aplikacji jest krok ćwiczenia, gdyż użytkownik spędza w nim najwięcej czasu. Początkowo użytkownik spotyka widok taki, jak na Rysunku 3.9. Na wykresie samogłosek tym razem można wyświetlić aż cztery zbiory danych:

- polskie samogłoski użytkownika, zebrane podczas wstępnej kalibracji,
- angielskie samogłoski użytkownika, zebrane podczas testu wstępnego,
- pomiary z badania Peterson & Barney [33], omówione dokładniej w Punkcie 3.3.1, które mają reprezentować modelową wymowę amerykańską, widoczne na Rysunku 3.10,
- pomiary wyciągnięte ze wspomnianych w poprzednim punkcie nagrań polityków, widoczne na Rysunku 3.11.

Każdy zbiór danych kodowany jest krojem pisma i stylem wypełnienia elips. Krój pisma ma znaczenie dla centroidów, chmur punktów i podpisu zbioru danych w legendzie. Korespondencje znajdują się w Tabeli 3.2. Użytkownik może wybrać, które zbiory danych chce widzieć na




Rysunek 3.9: Zrzut ekranu domyślnego widoku ćwiczenia



Rysunek 3.10: Zrzut ekranu reprezentujący zbiór danych Peterson & Barney [33]

3.1. DZIAŁANIE APLIKACJI




Rysunek 3.11: Zrzut ekranu reprezentujący pomiary formantów polityków

wykresie. Podobnie jak przy widoku kalibracji samogłosek, w momencie, gdy użytkownik mówi, pojawia się dodatkowo czarna kropka, która reprezentuje wygładzony pomiar formantów.

Tabela 3.2: Samogłoskowe zbiory danych dostępne w widoku ćwiczenia i odpowiadające im style reprezentacji

Zbiór danych	Krój pisma	Styl wypełnienia
polskie samogłoski użytkownika	szeryfowy	gradient
angielskie samogłoski użytkownika	<i>pochylony bezszeryfowy</i>	gradient
Peterson & Barney	pogrubiony bezszeryfowy	jednorodne, 60% przezroczystości
nagrania polityków	zwykły bezszeryfowy	jednorodne, 80% przezroczystości

Domyślnie widoczne są centroidy angielskich samogłosek użytkownika i elipsy dla badania Peterson & Barney. Użytkownik może wybierać, które zbiory danych i z jaką reprezentacją chce widzieć. Można je przełączać korzystając z przycisków znajdujących się w legendzie. Wszystkie reprezentacje angielskich samogłosek na wykresie podświetlają się po najechaniu na nie myszką, co ma sygnalizować, że można je kliknąć. Po kliknięciu znikają z wykresu wszystkie samogłoski angielskie poza wybraną i pokazują się na tle polskich samogłosek, jak to jest widoczne na Rysunku 3.12 w przypadku /u/. Ułatwia to zrozumienie, gdzie angielski fonem znajduje się w porównaniu do znanych, polskich samogłosek.



Rysunek 3.12: Zrzut ekranu widoku ćwiczenia angielskiego /u/

Wybranie samogłoski uruchamia również listę słów, w których ona występuje. Na liście można zobaczyć również transkrypcję fonologiczną wyrazu i jego tłumaczenie. Po naciśnięciu kolejnego przycisku można też podejrzeć przykładowe wyrażenie zawierające słowo i jego tłumaczenie. Niektóre ze słów i wyrażeń przypisane mają nagrania audio, których można odsłuchać. Nagrania te pochodzą z przemówień polityków, które były użyte w teście angielskiej wymowy.

Kolory dla angielskich samogłosek zostały dobrane w podobny sposób, jak dla polskich. Niektóre, jeśli brzmią podobnie, mają takie same kolory jak polskie (/u/, /i/, /ɔ/), a inne mają barwy pośrednie, podobne do sąsiednich fonemów. Jest to celowy zabieg, który sugeruje użytkownikowi metaforę przestrzeni kolorów, która — podobnie jak przestrzeń samogłosek — stanowi kontinuum.

Dodatkowo, w dowolnym momencie podczas ćwiczenia można sprawdzić ponownie swoje angielskie samogłoski. Opcja ta jest dostępna przez ustawienia, opisane dokładniej w następnym punkcie. Test wygląda identycznie jak opisano to w Punkcie 3.1.2. Następnie aplikacja wraca do widoku ćwiczenia, jednak tym razem użytkownik może wybrać dodatkowym przełącznikiem w legendzie, czy chce widzieć “stare samogłoski” z pierwszego testu wstępnego, czy też “nowe samogłoski” z aktualnego testu. W ten sposób użytkownik może porównywać swoje wyniki w czasie i oceniać, czy jego wymowa się poprawia.

3.2. WYBRANE ASPEKTY IMPLEMENTACJI

3.1.4. Ustawienia

Ustawienia

Pomoc

[Obejrzyj filmik instruktażowy](#)

Zgody

Zaakceptowano przechowywanie danych w pamięci lokalnej. Po wycofaniu zgody odświeżenie strony bądź zamknięcie przeglądarki spowoduje usunięcie wszystkich Twoich danych. [Polityka prywatności](#)

Wycofaj zgodę i wyczyść dane z pamięci lokalnej

Tylko wycofaj zgodę

Kategoria głosu

Wybierz kategorię, która najbardziej do Ciebie pasuje. Pamiętaj, aby kierować się charakterystyką swojego głosu, więc np. dla chłopca po mutacji najpewniej sprawdzi się opcja "męczyzna", niezależnie od wieku.

Jestem:

kobietą

mężczyzną ✓

dzieckiem

Kalibracja głośności

Poziomy cisy: 6.48e-11 / 1.12e-5 / 1.20e-3 Poziomy mowy: 2.90e-10 / 6.42e-4 / 1.73e-2

Kalibruj ponownie

Kalibruj ponownie, jeśli używasz innego mikrofonu, jesteś teraz w innym otoczeniu albo po prostu uważasz, że aplikacja nie wychwytuje dobrze, kiedy mówisz.

Sprawdź ponownie swoją wymowę

Sprawdź ponownie swoje angielskie samogłoski

Zapisz lub wczytaj

Zapisz stan aplikacji do pliku...

Wczytaj stan aplikacji z pliku...

Śledzenie czasu

Aplikacja śledzi, ile czasu spędzasz z nią każdego dnia.

Data	Czas
2025-4-15	0:17:39

Samogłoskop v1.6.0

Rysunek 3.13: Zrzut ekranu reprezentujący widok ustawień podczas ćwiczenia

W większości widoków w prawym górnym rogu znajduje się przycisk symbolizowany zębatką, którym można dostać się do ustawień. W tej zakładce znajduje się m.in. link do instrukcji wideo, możliwość zmiany kategorii głosu, ponownej kalibracji poziomów, zapisywanie i wczytywanie, czas spędzony w aplikacji każdego dnia, a także aktualna wersja. Część opcji staje się dostępna dopiero w widoku ćwiczenia, jak ponowne nagranie angielskich samogłosek. Widok ustawień przedstawiony jest na Rysunku 3.13.

3.1.5. Widok mobilny

W ramach częściowego dostosowania aplikacji do urządzeń mobilnych, układ elementów widoku zmienia się w zależności od orientacji ekranu. Widok analogiczny do Rysunku 3.5 można zobaczyć w orientacji pionowej na Rysunku 3.14. Zostały obrane przykładowe wymiary bazowane na smartfonie Google Pixel 7. *Samogłoskop* działa w pełni na urządzeniach mobilnych, natomiast niektóre elementy interfejsu czasami się niepoprawnie skalują.

3.2. Wybrane aspekty implementacji

Ten podrozdział skupia się na najważniejszych decyzjach, które podjęto przy projektowaniu i implementowaniu *Samogłoskopu*. Nie jest to, rzecz jasna, wyczerpująca lista, ale autor wyraża



Rysunek 3.14: Widok analogiczny do Rysunku 3.5 w orientacji pionowej, tym razem podczas wymawiania [u]

nadzieję, że pozwoli ona lepiej zrozumieć, jak działa program i dlaczego dokonane zostały takie wybory.

Cała aplikacja działa w przeglądarce, bez potrzeby komunikacji z serwerem. Rozwiązanie korzysta z klas ES6, które zorganizowane są według wzorca projektowego Model-View-Controller (MVC). Wzorzec ten pozwala na oddzielenie logiki aplikacji od jej interfejsu użytkownika. Dzięki temu możliwe jest łatwe dodawanie nowych funkcjonalności, a także testowanie poszczególnych komponentów. Większość *Samogłoskopu* stanowi aplikację jednostronicową (ang. Single Page Application), z wyjątkiem osobnych, statycznych stron z dodatkowymi informacjami. Repozytorium GitHub połączone jest z systemem ciągłej integracji GitHub Actions, który automatycznie buduje aplikację przy użyciu kompilatora TypeScript i publikuje ją na GitHub Pages. Dzięki temu możliwe jest szybkie wprowadzanie poprawek i nowych funkcjonalności.

3.2.1. Ekstrakcja formantów

Zarówno w kroku ćwiczenia, jak też kalibracji samogłosek oraz testu samogłosek angielskich, wykorzystywany jest algorytm Burga do wyodrębniania formantów i działa on w czasie rzeczywistym. Początkowo, podobnie jak jest to w *Vowel Viewerze*, planowano skorzystać z bi-

bioteki *parselmouth* dla języka Python. Postawiony został jednak priorytet, by trzymać się prostej architektury, nie wymagającej komunikacji z serwerem. Rozważano alternatywy w postaci korzystania z interpretera Pythona zaimplementowanego w JavaScript, jak *Pyodide*, jednak nie wspierają one wszystkich pakietów Pythona, w tym *parselmouth*. Brano również pod uwagę kompilację części kodu źródłowego *Praata* do WebAssembly, jednak wydzielenie samego algorytmu Burga z całego projektu okazało się zbyt wymagające. Ostatecznie zdecydowano się na ręczne przepisanie algorytmu do JavaScriptu, opierając się na kodzie źródłowym *Praata* i wspierając się bibliotekami takimi jak *math.js* i *emlapack*. Nie jest to idealne rozwiązanie, ponieważ algorytm Burga w *Praacie* jest napisany w C++ i jest znacznie bardziej zoptymalizowany. Mimo wszystko algorytm sprawdza się sprawnie w czasie rzeczywistym nawet na urządzeniach mobilnych. Pewnie można otrzymać odmienne wyniki niż przy użyciu oryginalnego algorytmu w granicznych przypadkach, ze względu na różnice w podstawowych typach numerycznych w C++ i JavaScript, jednak do tej pory nie spotkano zauważalnych rozbieżności.

Główny algorytm zawiera się w funkcji `soundToFormant`, która jest odpowiednikiem funkcji `Sound_to_Formant_burg` *Praata*. Poza sufitem formantów, w całej aplikacji przyjęte są jednokowe domyślne wartości parametrów: liczba formantów `nFormants = 5`, połowiczna długość okna `halfdt_window = 0.05`, częstotliwość preemfazy `preemphasisFrequency = 50`.

Co klatkę, która jest wywoływana przez przeglądarkę w funkcji `requestAnimationFrame`, do algorytmu podawana jest próbka dźwięku z mikrofonu z ostatnich 50 ms. Dzieje się to pod warunkiem, że mikrofon jest włączony, a dźwięk przekracza minimalny poziom natężenia głosu wyznaczony w czasie kalibracji. W przeciwnym wypadku w danej klatce ekstrakcja formantów jest pomijana. Zazwyczaj klatka trwa około 16 ms, co oznacza, że sąsiednie próbki częściowo pokrywają się ze sobą. Wynik algorytmu Burga z jednej klatki reprezentowany jest na wykresie jako jedna z małych półprzezroczystych kropek. Kiedy w dwudziestu kolejnych klatkach zostanie wykonany pomiar, jest liczona z niego średnia ważona jak w Równaniu (3.1) i przedstawiana jako jedna duża czarna kropka. $F_i[j]$ reprezentuje i -ty formant pozyskany z algorytmu Burga w j -tej klatce, a $S_i[j]$ to jego wygładzona postać. To wygładzone pomiary są trwale zapisywane podczas testów i kalibracji samogłosek. Z kolei współczynnik r został dobrany empirycznie, by wygładzić ruch dużej czarnej kropki w czasie i jednocześnie zachować wystarczający poziom dynamiki, by program cały czas wykazywał dużą responsywność.

$$S_i[j] = \frac{\sum_{k=0}^{19} F_i[j-k]r^k}{\sum_{k=0}^{19} r^k}, \quad r = \frac{1}{2} \quad (3.1)$$

3.2.2. Wybór samogłosek

Przyjęto sześciosamogłoskowy model języka polskiego pomijający samogłoski nosowe, które wymagają specjalnego traktowania, jak w pracy wspomnianej w Podrozdziale 2.5. Wybór ten jest zgodny z różnymi badaniami polskiej fonologii, a część z nich zupełnie nie wyodrębnia samogłosek nosowych jako fonemów w języku polskim [21, 22, 36, 37]. Wybrane samogłoski przedstawione są w Tabeli 3.3. W widokach aplikacji stosowany jest wyłącznie ich zapis ortograficzny, nie IPA, by ułatwić użytkownikowi ich rozpoznawanie.

Tabela 3.3: Polskie samogłoski zawarte w aplikacji

Fonem	i	ɐ	ɛ	a	ɔ	u
Zapis ortograficzny	i	y	e	a	o	u

Wybór samogłosek angielskich w dużej mierze zależał od dostępności i jakości danych. Obrano standard General American, bez zjawiska “*cot*”–“*caught*” *merger*, co jest powiązane też z wyborem zbioru danych, o którym mowa w Podrozdziale 3.3.1. Skupiono się na monoftongach, gdyż reprezentacja graficzna pojedynczych punktów w przestrzeni samogłosek, w przeciwieństwie do trajektorii, jest dużo bardziej czytelna. Pominęto zatem dźwięki takie jak /aɪ/, /aʊ/ i /ɔɪ/, a także /eɪ/ i /oʊ/, które w niektórych badaniach są traktowane jak monoftongi. Zdecydowano się również na pominięcie samogłosek rotacyjnych, do których pełnej analizy należy uwzględnić wartość F_3 , co utrudnia ich reprezentację graficzną. Wybranych zostało zatem 9 samogłosek, które wszystkie są przedstawione w Tabeli 3.4. Fonemy te i odpowiadające im oznaczenia w dużej mierze są zgodne z badaniami [43, 26]. Trzeba też zaznaczyć, że ortografia języka angielskiego jawi się jako bardzo niejednolita, co sprawia, że nie ma prostego przełożenia między fonemami a literami. Z tego powodu samogłoski angielskie w aplikacji oznaczane są za pomocą transkrypcji fonologicznej, mimo że wielu użytkowników może nie być z nią zaznajomionych. Podobnie w tabeli, oprócz fonemów, zamiast zapisów ortograficznych, podano całe słowa, a w nich pogrubiono litery reprezentujące samogłoskę. Wyrazy te pochodzą od Wellsa, brytyjskiego fonetyka, i są często używane do opisu systemów samogłoskowych różnych odmian języka angielskiego [43].

Tabela 3.4: Angielskie samogłoski (General American) zawarte w aplikacji wraz z reprezentującymi je słowami

Fonem	i	ɪ	ɛ	æ	ɑ	ʌ	ɔ	ʊ	u
Słowo	fleece	kit	dress	trap	palm	strut	thought	foot	goose

3.2.3. Normalizacja

Aby lepiej sugerować użytkownikowi, jak powinien mówić, w aplikacji zastosowana została normalizacja Lobanova. Przy czym należy zwrócić uwagę, że parametry $\overline{F}_i$ i σ_i , jak w Równaniu (2.1) w poprzednim rozdziale *dla użytkownika* wyznaczane są podczas kalibracji samogłosek i są zapisywane, a następnie podczas testów samogłosek angielskich i ćwiczeń są stosowane do normalizacji formantów wypowiedzianych z założenia nowych głosek. Pomiary te mają więc po normalizacji odnosić się do polskiego systemu samogłosek. Dla porównania, zbiory danych Peterson & Barney i polityków są normalizowane względem fonemów General American, co oznacza, że może pojawić się problem z porównywaniem dwóch języków ze sobą, jak to zaznaczono w Podrozdziale 2.3. W związku z tym, oprócz normalizacji zastosowano skalowanie formantów angielskich, kierując się tym, że fonemy /i/, /u/ i /ɔ/ są w przybliżeniu równoważne pomiędzy polskim a amerykańskim angielskim. Ponadto, wysokość polskiego /a/ powinna być mniej więcej podobna do wysokości amerykańskiego /ɑ/. Parametry dobrano empirycznie i można je zobaczyć w Równaniu (3.2). Należy pamiętać, że to skalowanie miało miejsce *po* normalizacji Lobanova. Z powodu błędu we wszystkich wersjach aplikacji, które były użyte w badaniach, skalowanie to jest niepoprawnie zaimplementowane dla formantów polityków, ponieważ oba formanty były mnożone przez 0,8. Niemniej jednak dane dla modelu Peterson & Barney są we wszystkich wersjach skalowane poprawnie.

$$\begin{aligned} F_1 &\rightarrow 0,8F_1 \\ F_2 &\rightarrow F_2 \end{aligned} \tag{3.2}$$

3.2.4. Automatyzacja badań

Aplikacja została od początku tworzona z myślą o automatyzacji badań, które opisano w tej pracy. Poza możliwością prowadzenia testów angielskiej wymowy, które można wykorzystać w modelu pre-test/post-test, aplikacja pozwala na przydział do grupy kontrolnej, której widok różnił się w zależności od wersji aplikacji. Przydział do grupy następował losowo i dopiero w momencie zakończenia testu wstępnego, czyli tuż przed krokiem ćwiczenia. Prawdopodobieństwo przydziału do grupy kontrolnej wynosiło 20% dla każdego użytkownika. W przypadku trafienia do grupy badawczej, aplikacja działała dokładnie tak, jak przedstawione jest to w Podrozdziale 3.1. Natomiast grupa kontrolna miała inny widok ćwiczenia. W wersji 1.2.0 widok ten zawierał listę samogłosek i pozwalał na przeglądanie listy słów i nagrań, ale nie oferował wizualizacji w postaci wykresu. W wersji 1.5.5 widok ćwiczenia był jeszcze bardziej ograniczony, ponieważ nie zawierał nawet listy samogłoskowej i wyświetlał jedynie przycisk zapisu i napis

z informacją, kiedy badany ma wrócić do aplikacji, żeby wziąć udział w teście końcowym.

W wersji 1.2.0 zarówno grupa badawcza, jak i grupa kontrolna widziały w widoku ćwiczenia przycisk pozwalający na przejście do testu końcowego w dowolnym momencie. Natomiast w wersji 1.5.5 przycisk ten został usunięty, a aplikacja przechodziła do testu końcowego automatycznie po spełnieniu odpowiedniego kryterium czasowego. Dla grupy badawczej tym kryterium było korzystanie z programu przez co najmniej 6 dni, przy czym liczyły się tylko te dni, dla których czas spędzony w aplikacji wynosił przynajmniej 30 minut. Grupa kontrolna przechodziła natomiast do testu końcowego po 8 dniach od zakończenia testu wstępnego, niezależnie od czasu spędzonego w aplikacji.

W wersji 1.5.5, po minięciu 30 minut danego dnia, wyświetlał się komunikat, że można danego dnia ćwiczenie zakończyć i kontynuować je następnego dnia. Odświeżenie przeglądarki w tym momencie blokowało dostęp do ćwiczenia aż do kolejnego dnia i pokazywała się informacja o spędzonym do tej pory w aplikacji czasie. W programie znajduje się również widok witający Użytkownika przy pierwszym uruchomieniu *Samogłoskopu* danego dnia. Oba te widoki zawierały też informację o obecnej passie użytkownika, czyli liczbie dni z rzędu, w których osiągnął cel 30 minut. Passa miała jedynie charakter kosmetyczny i nie wpływała na działanie aplikacji. Badani nie potrzebowali ćwiczyć 6 dni z rzędu, tylko 6 dni ogółem, żeby dostać się do testu końcowego.

Po przejściu do testu końcowego nie było już opcji cofnięcia się do widoku ćwiczenia. Test końcowy we wszystkich wersjach wyglądał tak samo, jak test wstępny, opisany w Punkcie 3.1.2. Po teście końcowym aplikacja przechodziła do widoku podsumowania, który zawierał jedynie opcję pobrania danych w formacie JSON lub ich usunięcia.

3.3. Dane w aplikacji

Warto skupić się na danych, które aplikacja przechowuje. Są to zarówno dane użytkownika, zbierane w trakcie korzystania z programu, jak i dane modelowe, które są identyczne dla wszystkich użytkowników.

3.3.1. Modelowe samogłoski angielskie

Język angielski określa się często mianem pluricentrycznego, co oznacza, że nie ma jednej ustandaryzowanej formy. Problematyczne jest to, że w przypadku tworzenia takiej aplikacji trzeba jeden model wybrać, choć nie można powiedzieć, że jedna forma języka jest bardziej poprawna od drugiej. Najczęściej nauczaną odmianą angielskiego w Polsce jest brytyjska, na-

zywana Received Pronunciation. Wybrano jednak standard General American, ponieważ właśnie dla niego znaleziono najlepszej jakości badania z pomiarami formantów. Aplikację można natomiast potencjalnie rozszerzyć o inne dialekty angielskiego, a nawet o inne języki, pod warunkiem dostarczenia dokładnych danych o formantach.

W szczególności badanie *Control methods used in a study of the vowels* przeprowadzone przez Gordona Petersona i Harolda Barney'ego (dalej po prostu: Peterson & Barney) [33] jest najczęściej cytowane w literaturze i zawiera pomiary dla 10 samogłoskowych fonemów amerykańskiego angielskiego. Dla uproszczenia odrzucono samogłoskę /ɜ:/, którą można alternatywnie analizować jako sekwencję /ʌ/. Pomimo, iż badanie to ma już ponad 70 lat, jest ono w dużej mierze wciąż aktualne. W porównaniu z innymi zbiorami danych, jak np. [17], wybór ten ma pewne zalety. Przede wszystkim, po normalizacji Lobanova jest bardzo małe przecięcie między różnymi fonemami, co wskazuje na homogeniczność mówców. Uczestnicy pochodzili głównie z rejonu Wielkich Jezior, którego dialekt jest oceniany za bardzo bliski do General American. W badaniu tym wzięło udział 76 mówców, co daje dużą próbę statystyczną. Co więcej, data badania sama w sobie jest w pewnym sensie sprzyjająca, gdyż w tym czasie dwie duże zmiany fonetyczne, które dziś dzielą mówców amerykańskiego angielskiego, dopiero się zaczynały. Pierwsza z nich określana jest jako /æ/ *raising* i charakteryzuje się tym, że w pewnych kontekstach fonem ten przesuwają się bliżej /e/ i często się dyftongizuje. Drugą jest natomiast fenomen nazwany „*cot*”–“*caught*” *merger*, który sprawia, że część osób traktuje /ɑ/ i /ɔ/ jako jeden fonem i wymawia je tak samo. Użycie nowszego zbioru danych zmniejszyłoby jednorodność, kiedy jedni mówcy wypowiadają samogłoski znacząco inaczej niż inni. Przegląd literatury na temat zbiorów danych pomiarów formantów amerykańskiego angielskiego [25] wskazuje, że pomimo długiej historii akustyki samogłosek, wciąż występuje problem fragmentaryzacji, gdzie każde badanie opisuje pomiary w trochę inny sposób i mogłyby one być bardziej szczegółowe. Uznano natomiast, że na cele *Samogłoskopu* zbiór Peterson & Barney jest jak najbardziej wystarczający.

Dla porównania, kluczowa praca na temat dialektu brytyjskiego [42] zawiera pomiary formantów dla jedynie 25 mówców, przy metodologii podobnej do badania Peterson & Barney. Istnieje bardziej obszerny zbiór danych, jednak jest to materiał dydaktyczny jako część kursu na temat uczenia głębokiego i nie ma podanego dla niego pierwotnego źródła [39].

3.3.2. Nagrania polityków

Udźwiękowanie *Samogłoskopu* oparte jest na dwóch nagraniach audio polityków. Pierwszym z nich jest wypowiedź Hillary Clinton, ówczesnej pierwszej damy USA, z 1995 roku na IV

Konferencji Kobiet w Pekinie. Drugie pochodzi z przemówienia prezydenta Donalda Trumpa po wyborach prezydenckich w 2020 roku, w których został pokonany przez Joe Bidena.

Nagrania te zostały wybrane, gdyż są dostępne w domenie publicznej jako materiały przygotowywane przez pracowników rządu federalnego Stanów Zjednoczonych. Przedstawieni mówcy są jednymi z najbardziej znanych amerykańskich polityków, co daje użytkownikowi znany punkt referencyjny. Celowo wybrana została też jedna kobieta i jeden mężczyzna, ze względu na różnice w wymowie między płciami. Ponadto upewniono się, że pomiary formantów na podstawie plików audio przemówień są zbliżone do standardu. Mowa Donalda Trumpa nosi charakterystykę akcentu nowojorskiego, a Hillary Clinton cechuje się dialektem rejonu Chicago z pewnym wpływem wymowy ze stanów południowych. W obu przypadkach mieszczą się one w zakresie General American, co czyni je odpowiednimi do porównań z danymi Peterson & Barney.

Nagrania przetworzono z użyciem programu *Praat*. Wybrano z nich sylaby, w których samogłoski są możliwie długie i wyraźne, co nie zawsze było możliwe. Dokładnie oznaczono początek i koniec samogłoski. W dalszej kolejności zidentyfikowano słowa i dodano transkrypcję fonologiczną w oparciu o własną wiedzę i słowniki fonetyczne. Nie wszystkie samogłoski w słowie były oznaczone, ale na część słów przypada więcej niż jedna wyraźnie powiedziana samogłoska. Wskazano też ramy czasowe wyrażeń zawierających zaznaczone fonemy i dodano ich tłumaczenie. Statystyki dotyczące nagrań i wydzielonych fragmentów można znaleźć w Tabeli 3.5.

Tabela 3.5: Liczebność zidentyfikowanych fragmentów nagrań polityków i ich podział na kategorie

	Wyrażenia	Słowa	Samogłoski									Razem
			i	ɪ	ε	æ	ɑ	ʌ	ɔ	ʊ	u	
Hillary	15	16	2	2	2	2	2	3	2	1	2	18
Trump	17	19	5	4	2	2	3	3	2	2	2	25
Razem	32	35	7	6	4	4	5	6	4	3	4	43

Przy użyciu zmodyfikowanej wersji aplikacji przeanalizowano wszystkie ręcznie wyizolowane samogłoski algorytmem Burga — tym samym, który jest używany w czasie rzeczywistym do interpretacji danych z mikrofonu. W ten sposób uzyskano wyniki, jakie mogliby uzyskać amerykańscy mówcy, dla których angielski jest językiem rodzimym przy korzystaniu z *Samogłoskopu*. Zdobyte pomiary formantów dostępne są również w wizualnej reprezentacji, jak to można było zobaczyć na Rysunku 3.11. Dzięki temu użytkownik może porównać je z modelowym badaniem Peterson & Barney i ocenić, jakie są akceptowalne odchyły od modelowej wymowy.

3.3. DANE W APLIKACJI

Trzeba jednak zastrzec, że nagrania te są mimo wszystko dość krótkie, a w takim przypadku aplikacja mniej sobie radzi z wyznaczaniem wartości formantów. Wycięcie audio z kontekstu różnych wyrazów zamiast operowania na wypowiedziach, gdzie mówcy byli instruowani, żeby mówić samogłoski w izolacji, również przyczynia się do dużej rozbieżności pomiarów. Można to zwłaszcza zauważyć w aplikacji w przypadku fonemu /ɪ/. Dlatego też główny model wymowy amerykańskiej oparty jest wciąż na badaniu Peterson & Barney, co aplikacja sugeruje przez domyślne jego wyświetlanie, pogrubienie symboli na wykresie i mniej przezroczyste elipsy.

3.3.3. Dane użytkownika

Program korzysta z pamięci lokalnej przeglądarki (ang. Local Storage), aby zapisywać stan aplikacji i dane użytkownika. Dzięki temu możliwe jest korzystanie z aplikacji bez potrzeby logowania się. Aby umożliwić przechowywanie danych na różnych urządzeniach, aplikacja pozwala na eksport i import danych w formacie JSON. Użytkownik może również usunąć wszystkie dane z pamięci lokalnej, co jest przydatne w przypadku zmiany urządzenia lub przeglądarki. *Samogłoskop* pyta o zgodę na przechowywanie danych — jeśli takowa nie zostanie wyrażona, dane zostają usunięte w momencie zamknięcia aplikacji lub odświeżenia strony. Uczestnicy badania byli instruowani, żeby wyrazić zgodę na przechowywanie danych.

Aplikacja zaimplementowana jest w formie statycznej strony, tak więc nie komunikuje się z żadnym serwerem. Dane do badania były zbierane w formie plików eksportowanych ze strony. Ostateczny plik wynikowy, podobnie jak plik zapisu, zawierał następujące dane:

- wersję aplikacji w momencie eksportu,
- wybraną przez użytkownika kategorię głosu,
- stan aplikacji, mówiący o aktualnym widoku i aktywności,
- informacje o poziomach kalibracji, tj. statystyki najmniejszego, średniego i największego poziomu natężenia dźwięku ciszy i dźwięku mowy,
- formanty samogłosek polskich zebranych podczas kalibracji, wraz z datą, po normalizacji Lobanova, a także średnie i odchylenia standardowe dla całej przestrzeni samogłosek, tak żeby można było odwrócić normalizację,
- formanty samogłosek angielskich zebrane podczas testów, znormalizowane względem polskiej przestrzeni samogłosek użytkownika podanej powyżej oraz daty i godziny przeprowadzenia każdego z testów, przy czym maksymalnie zapisywane były trzy testy (pierwszy, przedostatni i ostatni),

- dziennik zawierający czas spędzony w aplikacji w milisekundach dla każdego dnia, w którym użytkownik korzystał z aplikacji,¹
- informację o przydziale do grupy kontrolnej,
- nazwę systemową mikrofonu, który był używany w momencie nagrywania.

Warto nadmienić, że *nie* były trwale zapisywane nagrania audio użytkownika, a jedynie wydobyte z nich automatycznie formanty.

3.4. Wersje

W trakcie rozwijania aplikacji, przyjęto system wersjonowania inspirowany Semantic Versioning na następujących zasadach:

- Pierwsza liczba (major) zmieniła się w momencie rozpoczęcia testów z użytkownikami. Wersja 1.0.0 była pierwszą wersją, która była testowana przez uczestników badania.
- Druga liczba (minor) zmieniała się wraz ze zmianą struktury danych zapisywanych w `localStorage`. Każda nowa wersja na tym poziomie wymagała konwersji danych z poprzedniej wersji, która następowała automatycznie przy pierwszym uruchomieniu aplikacji po aktualizacji.
- Trzecia liczba (patch) zmieniała się przy każdej aktualizacji aplikacji, która była wydana publicznie. Nie wymagała ona żadnych zmian w strukturze danych, a jedynie zawierała poprawki błędów lub dodanie nowych funkcjonalności. Wersje, które nie były udostępniane publicznie, nie były osobno numerowane.

Gdzie nie było podane inaczej, opisane dotychczas funkcje znajdują się w wersji 1.5.5, która była ostatnią wersją użytą w badaniach. W poprzednich etapach badań używane były też wersje 1.0.0 i 1.2.0, które różniły się w następujący sposób:

- Wersja 1.2.0 śledziła czas spędzony tylko w widoku ćwiczenia i nie dzieliła go na dni. Nie było możliwości ponownego sprawdzenia swoich angielskich samogłosek. Zapisywanie i wczytywanie stanu aplikacji również nie było jeszcze dodane. Program nie przechowywał dat i godzin przeprowadzenia testów angielskich samogłosek.

¹Śledzenie czasu spędzonego w aplikacji polega na zdarzeniach `focus` i `blur` okna przeglądarki. W momencie, gdy użytkownik przełącza się do innej karty, mierzenie czasu jest wstrzymywane. Czas był zapisywany w momencie zamknięcia, przełączenia karty lub odświeżenia strony.

3.4. WERSJE

- Wersja 1.0.0 podczas testu nie pozwalała na ponowne odsłuchanie swojej próby angielskiej samogłoski i automatycznie zapisywała pierwsze podejście. Nie była jeszcze wspierana obsługa grupy kontrolnej, ani nie była zapisywana nazwa systemowa używanego mikrofonu. Naturalnie wersja 1.0.0 nie zawierała też funkcji brakujących w wersji 1.2.0.

4. Projekt badania

Badanie odbyło się w trzech etapach. Pierwszy z nich obejmował indywidualne sesje z pojedynczymi uczestnikami, który miał za zadanie głównie poinformować o odczuciach związanych z aplikacją i uwypuklić największe błędy. Drugi etap obejmował większą grupę osób i obejmował zarówno sesje indywidualne jak i grupowe. Wprowadzona została grupa kontrolna, która na etapie badania nie widziała wykresu przestrzeni samogłosek. Po niekonkluzywnych wynikach z pierwszych dwóch etapów, podjęta została decyzja o trzecim etapie, obejmującym wielosesyjne badania na przestrzeni dwóch tygodni, przeprowadzone tym razem online. W pierwszych dwóch etapach uczestnicy byli również pytani na koniec o swoje odczucia związane z aplikacją. Pomiędzy etapami aplikacja była cały czas rozwijana z uwzględnieniem uwag uczestników. Najważniejsze informacje o różnicach między etapami zobaczyć można w Tabeli 4.1.

Tabela 4.1: Różnice między etapami badania

Etap	Grupa kontrolna	Typ sesji	Długość	Wersja aplikacji
1	Brak	Na żywo	Jednosesyjne	1.0.0
2	Obecna	Na żywo	Jednosesyjne	1.2.0
3	Obecna	Online	Wielosesyjne	1.5.5

Przyjęto schemat badawczy pre-test/post-test, gdzie testy były przeprowadzane w sposób przedstawiony w Punkcie 3.1.2. W trzecim etapie badania użytkownicy mogli też uruchamiać test ponownie przed zakończeniem ćwiczenia, co nie liczyło się ani jako pre-, ani post-test, a miało jedynie charakter informacyjny dla badanego. Uczestnicy badania nie otrzymywali numerycznych ocen swojego testu, oceny trafności samogłosek zostały przeprowadzone offline po zakończeniu badania. Przyjęto hipotezę badawczą, że *użytkownicy, którzy skorzystali z aplikacji, odnotują lepsze wyniki w teście po skorzystaniu z aplikacji, niż przed, i że ta poprawa będzie istotnie większa w grupie badawczej niż w grupie kontrolnej.*

Trafność samogłosek mierzona była na podstawie średniej odległości Mahalanobisa (d_M) formantów wypowiedzianej samogłoski od wzorca z badania Peterson & Barney [33]. Im mniejsza odległość, tym lepsza jest trafność samogłoski. Odległość Mahalanobisa mierzona była na

4.1. ZBIERANIE DANYCH

podstawie centroidu samogłosek wypowiedzianej i wzorcowej oraz macierzy kowariancji dla samogłoski ze zbioru danych Peterson & Barney.

Tabela 4.2: Odległości Mahalanobisa wypowiedzi amerykańskich mówców od wzorca Peterson & Barney.

Dane		i	ɪ	ε	æ	ɑ	ʌ	ɔ	ʊ	u	Razem
Politycy	Hillary	1,53	4,54	2,98	2,84	1,18	1,63	1,55	1,04	5,72	2,56
	Trump	2,59	3,30	3,85	2,40	0,56	1,67	1,43	4,74	2,14	2,52
Peterson	$\overline{d_M}$	1,10	0,97	1,10	1,10	1,04	1,14	1,16	1,05	1,16	1,09
& Barney	σ	0,61	0,62	0,61	0,62	0,60	0,52	0,54	0,57	0,57	0,59

Celem dalszego porównania, odległości Mahalanobisa samogłosek mówców amerykańskich zawartych w aplikacji można zobaczyć w Tabeli 4.2. Można zatem sobie wyobrazić, że gdyby ojczyści mówcy General American skorzystali z *Samogłoskopu*, otrzymaliby podobne wartości d_M . Znajdują się tam też statystyki dla odległości mowy samych uczestników badania Peterson & Barney, czyli w uproszczeniu — porównano zbiór danych sam ze sobą.

4.1. Zbieranie danych

W każdym etapie przed skorzystaniem z aplikacji uczestnicy zapoznawani byli z przebiegiem badania i odpowiadali na krótką ankietę, która obejmowała następujące pytania:

- Jaki jest Twój język ojczysty?²
- Oceń w skali 1–10 swoją znajomość języka angielskiego.
- Oceń w skali 1–10 swoją znajomość wymowy amerykańskiej (General American).
- Jak dobrze rozumiesz, co oznaczają następujące symbole? **ɑ**, **æ**, **ε**, **i**, **ɪ**, **u**, **ʊ**, **ʌ**, **ɔ** (do zaznaczenia na 10 punktowej skali od *Zupełnie nie rozumiem* do *Doskonale rozumiem*)
- Ile języków obcych znasz na poziomie komunikatywnym?
- Wybierz swoją kategorię wiekową. (do wyboru: poniżej 20 lat, 20–29 lat, 30–39 lat, 40–49 lat, 50–59 lat, 60 lat lub więcej)
- Podaj swoją płeć.

²Do pytania dołączone było następujące doprecyzowanie: *Ewentualnie, jeśli masz więcej niż jeden język ojczysty (np. dwójka rodziców z różnych krajów), wymień je wszystkie. Jako język ojczysty uznaję język nauczony przed 5 rokiem życia.*

- Podaj swój poziom wykształcenia.

Wszystkie pytania były obowiązkowe. W przypadku pytania o płeć i poziom wykształcenia, można było wybrać jedną z podanych opcji lub napisać własną odpowiedź. Badanie dotyczyło jedynie osób, dla których polski jest językiem ojczystym, więc pierwsze pytanie pełniło tylko rolę weryfikacyjną.

Na koniec, w przypadku pierwszych dwóch etapów, badani proszeni byli o załączenie pliku z wynikami z aplikacji lub robił to prowadzący badanie. W przypadku trzeciego etapu, badani proszeni byli o wysłanie pliku wynikowego mailowo lub przez inny komunikator internetowy. Końcowy plik JSON wyglądał tak, jak jest to opisane w Punkcie 3.3.3.

4.2. Dobór uczestników

Uczestnicy badania nie byli losowo dobierani. W dużej mierze uczestnicy byli rekrutowani wśród znajomych i studentów Wydziału Matematyki i Nauk Informacyjnych Politechniki Warszawskiej. Chętni zachęceni również byli do przesyłania linku do badań swoim znajomym. Badani mogli też zgłosić się internetowo po napotkaniu materiału promocyjnego w serwisie YouTube. Wszyscy uczestnicy byli informowani o celu i charakterze badania. Mimo, że aplikacja była dostępna publicznie, link do niej był rozsyłany tylko do osób, które wzięły już udział w badaniu. Osoby z poprzednich etapów badania mogły też wziąć udział w trzecim etapie — nie musiały wtedy wypełniać ankiety wstępnej ponownie. Uczestnicy badania nie otrzymali żadnych nagród finansowych za udział w badaniu.

Każdemu uczestnikowi przypisany był unikalny, anonimowy identyfikator, który był losowany w zakresie od 000 do 999. W przypadku wylosowania duplikatu, losowanie było powtarzane aż do otrzymania unikatowego numeru. Adresy e-mail były przechowywane oddzielnie od danych użytkowników, były wykorzystywane jedynie do kontaktu z uczestnikami badania i nie zostały nigdzie udostępnione.

4.3. Przebieg badania

W przypadku pierwszych dwóch etapów, badanie odbyło się w całości w budynku Wydziału Matematyki i Nauk Informacyjnych Politechniki Warszawskiej. Sesje odbywały się w różnych salach laboratoryjnych o różnych poziomach hałasu. Uczestnicy korzystali albo z prywatnego laptopa prowadzącego badanie, albo z identycznych do siebie stacji roboczych dostępnych

4.3. PRZEBIEG BADANIA

w laboratoriach. Wszystkie komputery miały monitory o przekątnej co najmniej 15 cali, mysz, klawiaturę oraz słuchawki z mikrofonem. Modele słuchawek użyte w tych etapach to *Tracer Hydra* i *Logitech ClearChat Pro*. W przypadku trzeciego etapu, badanie odbywało się w całości online. Uczestnicy korzystali z własnego sprzętu i mieli w tym zakresie dowolny wybór, pod warunkiem, żeby przez cały czas trwania badania korzystać z tej samej konfiguracji urządzeń. Otrzymali natomiast zalecenie użycia dobrej jakości mikrofonu.

Na początku zapoznawano uczestników badania z jego przebiegiem oraz niedoskonałościami w aplikacji, na które warto zwrócić uwagę. Na drugi etap część informacji wprowadzających została przeniesiona do instrukcji wideo. Następnie badani byli proszeni o wypełnienie ankiety, a po jej zakończeniu otwierali *Samogłoskop*. Przechodzili przez kolejne kroki aplikacji: kalibrację, test wstępny (pre-test) i ćwiczenie. W przypadku pierwszych dwóch etapów, użytkownicy mogli zakończyć krok ćwiczenia w dowolnym momencie.

W trzecim etapie zamieniona została kolejność wypełniania ankiety i wprowadzenia do badania, które zostało przeprowadzone w postaci spotkań grupowych online. Rozszerzono badanie na więcej sesji, a test końcowy był dostępny dopiero po przećwiczeniu 6 pełnych dni (niekoniecznie z rzędu). Jako pełny dzień liczyło się korzystanie z aplikacji danego dnia przynajmniej przez 30 minut. Badani mogli wybrać, w które dni i o jakiej porze dnia chcą ćwiczyć. Ćwiczenie mogło być też przerwane i kontynuowane, więc przykładowo: ćwiczenie 20 minut rano, a następnie 10 minut wieczorem tego samego dnia, również zaliczało się jako pełny dzień. W związku z wielosesyjnym charakterem trzeciego etapu, uczestnicy zachęcani byli do regularnego zapisywania swojego postępu.

W obu przypadkach po zakończeniu post-testu uczestnicy przechodzili do widoku, gdzie mogli jedynie pobrać dane. W przypadku pierwszych dwóch etapów, prowadzący podchodził wtedy do uczestnika, zbierał plik z wynikami i pytał o odczucia związane z aplikacją. W trzecim etapie użytkownicy sami przesyłali swoje pliki z wynikami.

Wszyscy uczestnicy badania przez cały czas mieli możliwość skontaktowania się z prowadzącym badanie w celu zadania pytań lub zgłoszenia problemów. Podczas pierwszych dwóch etapów uczestnicy byli przez większość czasu nadzorowani. Prowadzący starał się stworzyć przyjazną atmosferę, aby badani czuli się komfortowo, nie bali się zadawać pytań, ani nie czuli się oceniani pod względem swoich umiejętności językowych lub wymowy.

5. Otrzymane wyniki

W badaniu udział wzięły łącznie 34 osoby, w tym 5 w pierwszym etapie, 15 w drugim etapie, 13 w trzecim etapie i dodatkowo jedna osoba zarówno w pierwszym, jak i w trzecim etapie. Oprócz tego, dwie osoby zaczęły korzystać z aplikacji w ramach trzeciego etapu badań i zostały przydzielone do grupy badawczej, ale zrezygnowały z badania w trakcie. Nie są one dalej liczone. Rozmiar grupy kontrolnej w drugim etapie wyniósł 4 (26,7%), a w trzecim 6 (40%). Są to większe ułamki niż wartość spodziewana, co można wyjaśnić indywidualnym charakterem losowania grupy przez aplikację i osobami, które nie ukończyły badania. Warto zauważyć, że w pierwszym etapie nie było grupy kontrolnej, ponieważ aplikacja nie miała jeszcze odpowiedniej funkcjonalności.

Z racji, że pierwsze dwa etapy badania były przeprowadzone w podobnej do siebie formule — a największą różnicą jest obecność grupy kontrolnej — oraz nie dały satysfakcjonujących wyników, w dalszej części będę liczył je łącznie. Zatem razem w pierwszych dwóch etapach (E1&2) uczestniczyło $n_{1\&2} = 5 + 15 + 1 = 21$ osób, a w etapie trzecim (E3) $n_3 = 13 + 1 = 14$ osób. Wszyscy uczestnicy badania byli Polakami i nie mieli innych języków ojczystych niż polski.

Etap	1&2	3
Kobiety	6	1
Mężczyźni	13	14
Inna płeć	2	0
20–29 lat	17	15
30–39 lat	4	0
Wykształcenie średnie	6	0
Wykształcenie wyższe I stopnia	9	14
Wykształcenie wyższe II stopnia	7	1

Tabela 5.1: Demografia uczestników badania

Demografia uczestników badania przedstawiona jest w Tabeli 5.1, przy czym należy pamiętać, że osoba, która wzięła udział w Etapach 1 i 3 była liczona raz dla kolumny E1&2 i ponownie,

raz dla kolumny E3 (lecz nie musiała ona wypełniać ankiety dwukrotnie). Przedstawiony został podział na płeć, wiek oraz wykształcenie. Większość uczestników badania stanowili mężczyźni, największa grupa wiekowa to 20–29 lat, a najczęstszy poziom wykształcenia to wyższe I stopnia — przy czym w etapie 3 różnorodność we wszystkich tych kategoriach była mniejsza.


Etap	E1&2		E3	
Wartość	Średnia	Odch. std.	Średnia	Odch. std.
Znajomość angielskiego (1–10)	7,4	1,5	8,3	1,2
Znajomość wymowy amerykańskiej (1–10)	5,6	1,7	7,1	1,8
Rozumienie symboli fonetycznych (1–10)	3,1	2,3	4,7	3,2
Liczba języków obcych	1,6	0,7	1,6	0,6

Tabela 5.2: Statystyki dla pytań o odpowiedziach całkowitoliczbowych


Odpowiedzi na pozostałe pytania w ankiecie miały postać liczb całkowitych, toteż przedstawiono w Tabeli 5.2 wartości średnie i odchylenia standardowe dla każdego z pytań. Można zauważyć, że średnie odpowiedzi na pytania o znajomość angielskiego, amerykańskiej wymowy oraz symboli fonetycznych wzrosły w etapie 3 w porównaniu do etapów 1 i 2. Ponadto można zobaczyć, że ocena wymowy i fonetyki jest średnio mniejsza od znajomości języka samego w sobie. Jest to zgodne z tezą, że wymowa jest w Polsce często pomijana w procesie nauczania języka angielskiego. Zwłaszcza rozumienie symboli fonetycznych było bardzo niskie, co *Samogłoskop* ma na celu poprawić. Co ciekawe, średnia liczba znanych języków obcych nie zmieniła się pomiędzy etapami.

Poza tym, na Rysunku 5.1 przedstawiony jest bąbelkowy wykres, który ilustruje znajomość angielskiego i amerykańskiej wymowy wśród uczestników badania. Położenie bąbelków w poszczególnych osiach związane jest z odpowiedziami na pytania, a ich pole powierzchni z liczbą osób, które udzieliły takich odpowiedzi. Warto zwrócić uwagę, że niebieskie i czerwone bąbelki są półprzezroczyste i w niektórych miejscach nakładają się na siebie, tworząc amarantowy kolor. Ten wykres pokazuje dość jasną korelację między znajomością języka angielskiego, a jego wymowy amerykańskiej. Przerywana linia pokazuje punkty, gdzie te oceny są równe, tak więc im niżej bąbelek jest od tej linii, tym mniej uczestnik zna amerykańską wymowę w porównaniu do znajomości angielskiego. Mogą to być osoby, które są bardziej zaznajomione z wymową brytyjską lub czujące się mniej pewnie w aspekcie wymowy ogółem. Co ciekawe, nikt nie ocenił swojej znajomości wymowy amerykańskiej wyżej od znajomości języka angielskiego.


W przypadku pozostałych dwóch pytań, nie zauważono żadnej znaczącej korelacji z odpowiedziami na inne pytania. Przedstawione zostały zatem na dwóch osobnych histogramach



Rysunek 5.1: Bąbelkowy wykres przedstawiający znajomość angielskiego i amerykańskiej wymowy wśród uczestników badania



Rysunek 5.2: Histogram przedstawiający znajomość symboli fonetycznych wśród uczestników badania




Rysunek 5.3: Histogram przedstawiający liczbę języków obcych, które znali uczestnicy badania


(Rysunki 5.2 i 5.3). Można na nich zauważyć, że znajomość symboli fonetycznych dla E1&2 miała tendencję do rozkładu skupionego wokół 1, a dla E3 rozkład ten był bardziej nieregularny. Co ciekawe, w obu przypadkach jest zauważalny nadmiar odpowiedzi równej 5, co może sugerować, że część uczestników badania miała tendencję do wybrania jak najbardziej “pośrodkowej” liczby. W przypadku liczby języków obcych, rozkład jest dość spodziewany. Ciekawi jedynie, że w trzecim etapie było tyle samo osób trójjęzycznych (język ojczysty i dwa obce), co dwujęzycznych (polski i jeden język obcy). Nie było natomiast osób, które znały więcej niż trzy języki obce.

W plikach wynikowych znajdowały się też informacje o polskich samogłoskach uczestników, na podstawie których była prowadzona normalizacja. Podstawą tej normalizacji są średnie wartości formantów dla całej przestrzeni samogłosek, które przedstawiono z podziałem na płeć na Rysunku 5.4. Jak można było się spodziewać, mężczyźni mają z reguły niższe oba formanty, co jest zgodne z teorią, że mają większe aparaty głosowe od kobiet. Co ciekawe, osoby które w formularzu zaznaczyły inną płeć, niż męczyzna lub kobieta, miały wartość F_1 bardziej zbliżoną do mężczyzn, a F_2 bardziej do kobiet. Z pewnością jest to interesujący temat do dalszych badań, ponieważ ciężko to wytłumaczyć jedynie różnicą w aparacie głosowym.

Po normalizacji samogłoski polskie uczestników prezentują się dość jednorodnie i wyraźnie widać granice pomiędzy fonemami, nie licząc dwóch realizacji głoski /u/. Na Rysunku 5.5 przedstawiono wykres punktowy, na którym średnie formanty każdego fonemu dla każdego uczestnika są oznaczone literami symbolizującymi dany fonem w zapisie ortograficznym. Na



Rysunek 5.4: Wykres przedstawiający średnie formanty przestrzeni samogłosek osób badanych z podziałem na płeć




Rysunek 5.5: Wykres punktowy przedstawiający formanty polskich samogłosek. Każdy punkt odpowiada realizacji samogłoski przez jednego uczestnika badania.

5.1. WYNIKI PIERWSZYCH DWÓCH ETAPÓW

wykreście znajdują się także elipsy niepewności, kryjące 95% punktów dla każdej samogłoski. Środki elips mieszczą się w punktach odpowiadających średnim wartościom formantów dla polskich fonemów.

5.1. Wyniki pierwszych dwóch etapów




Rysunek 5.6: Skumulowany histogram czasu ćwiczenia przez uczestników E1&2


W E1&2 ważny był czas ćwiczenia, który każdy z badanych dobierał samodzielnie, w przeciwieństwie do E3. Na Rysunku 5.6 przedstawiony jest wykres, gdzie czas był zaokrąglany w dół, do pełnych minut. Jak widać, większość uczestników (nawet pośród grupy badawczej) ćwiczyła mniej niż 10 minut. Jedynie dwie osoby ćwiczyły więcej niż 20 minut. Warto zauważyć, że w przypadku grupy kontrolnej, czas ćwiczenia był znacznie krótszy niż w grupie badawczej, czego można było się spodziewać. Jedna osoba już po 28 sekundach zdecydowała się przejść do testu końcowego.

W danych wyjściowych znajdowały się też informacje o poziomach dźwięku zebranych podczas kalibracji. Dla każdej osoby przechowywane było 6 wartości poziomów: minimum, średnia i maksimum głośności mowy (L_m), oraz minimum, średnia i maksimum głośności otoczenia (L_o). Na Rysunku 5.7 przedstawione są wykresy pudełkowe dla obu modeli słuchawek. Jak widać, ogólnie poziomy hałas były mniejsze od średnich poziomów głosu. Żeby jednak dobrze porównać dwa modele mikrofonów, należy skorzystać z miary względnej. Uznano, że najlepszym wyznacznikiem jakości będzie różnica:

$$Q = \overline{L_m} - \max L_o \quad (5.1)$$



Rysunek 5.7: Wykres pudełkowe przedstawiające bezwzględne poziomy zebrane podczas kalibracji dla obu modeli słuchawek w E1&2



Rysunek 5.8: Wykres pudełkowy przedstawiający różnice między średnim poziomem mowy a maksymalnym poziomem hałasu dla E1&2

5.1. WYNIKI PIERWSZYCH DWÓCH ETAPÓW

Można tę różnicę zobaczyć na Rysunku 5.8. Pod tym względem model *Tracer Hydra* wypadł lepiej, a w przypadku *Logitech ClearChat Pro* różnica ta była nawet w jednym przypadku ujemna, co znaczy, że największy zarejestrowany hałas był większy od średniej głośności mowy.

5.1.1. Trafność samogłosek

	Pre-test		Post-test	
	$\overline{d_M}$	σ	$\overline{d_M}$	σ
Grupa kontrolna	3,99	2,69	4,15	2,38
Grupa badawcza	4,91	4,55	4,52	3,61

Tabela 5.3: Statystyki odległości Mahalanobisa dla grupy kontrolnej i badawczej w E1&2

Trafność samogłosek oceniano na podstawie odległości Mahalanobisa (d_M). Jest to bezwymiarowa wielkość wskazująca na odstępstwo pomiaru od zadanego wielowymiarowego rozkładu normalnego. Ze względu na to, że w aplikacji zbiory danych dla angielskich samogłosek były skalowane w F_2 , jak to jest w Równaniu (3.2), porównywano dane z testów użytkownika z tak właśnie przetransformowanymi danymi ze zbioru Peterson & Barney. Warto zwrócić uwagę, że absolutna skala w obu osiach nie ma znaczenia, gdyż odległość Mahalanobisa nie zależy od skalowania w dowolnym kierunku. Ważne jest tylko to, żeby oba zbiory danych były dopasowane do tej samej skali. Dla każdego użytkownika wyznaczono centroidy jego samogłosek angielskich na podstawie danych z testów amerykańskiej wymowy. Obliczono średnie wartości odległości tych centroidów od samogłosek modelowych osobno dla grupy kontrolnej i badawczej, a także z podziałem na pre-test i post-test. Wyniki można zobaczyć w Tabeli 5.3. Należy pamiętać, że im niższa wartość odległości, tym większa trafność samogłosek.

Jak można zauważyć, w grupie badawczej jest ogółem niewielka poprawa, natomiast w grupie kontrolnej wyniki się nawet pogorszyły. Jednak różnice te są mniejsze niż różnica między grupą kontrolną a badawczą w pre-teście. Różnica ta powinna być równa zero, gdyż obie grupy dowiadywały się o przydziale dopiero po zakończeniu pre-testu. Do tego momentu badanie wyglądało dla obu grup tak samo.

Próbowano wykonać regresję liniową na wartościach reprezentujących zmianę odległości Mahalanobisa $\log d_M^{post} - \log d_M^{pre}$, zwłaszcza dla grupy kontrolnej, w zależności od czasu ćwiczenia, ale nie zauważono żadnej znaczącej korelacji ($R^2 < 0,2$). Poprawa nie zdawała się też być w żaden sposób zależna od odpowiedzi na pytania z ankiety wstępnej — w szczególności, o znajomość języka angielskiego, wymowy amerykańskiej i symboli fonetycznych —

ani od wartości Q opisującej stosunek poziomów mowy do hałasu (Równanie 5.1). Wyodrębnianie poszczególnych samogłosek i analiza względem czasu ćwiczenia dawała równie niskie współczynniki korelacji.

Skorzystano również z metody efektów mieszanych, która pozwala na uwzględnienie efektów losowych, takich jak różnice między uczestnikami. W tym przypadku efektem losowym był uczestnik, a efektami stałymi: grupa (badawcza lub kontrolna), który test jest rozważany (pre- lub post-test) oraz interakcja między nimi. Użyto w tym celu języka Python i biblioteki *statsmodels*. Nie otrzymano jednak statystycznie istotnych dopasowań ($p \gg 0,05$), nawet przy rozważaniu dodatkowych parametrów czy filtrowaniu danych.

5.1.2. Analiza jakościowa

Większość uczestników badania wyrażało pozytywne odczucia związane z aplikacją. Najbardziej doceniany był aspekt wizualizacji, analityczne podejście i przejrzysty sposób przedstawienia przestrzeni samogłosek. Wykres i jego aspekt działania w czasie rzeczywistym był dla badanych szczególnie pomocny. Jedna osoba podkreśliła też, że pozytywnym aspektem dla niej była możliwość wyodrębnienia widoku jednej samogłoski, jak to było pokazane na Rysunku 3.12. Wiele osób wskazywało też na potencjał aplikacji w nauce wymowy i oryginalność pomysłu. *Samogłoskop* określany był też jako intuicyjny, choć z pewnymi zastrzeżeniami. Zdecydowanie największym problemem była rozbieżność między krótkimi wycinkami z nagrań polityków, a długimi samogłoskami, których aplikacja wymagała od użytkownika. Ponadto mechanizm nagrywania dźwięku z mikrofonu był często mylący. Jedna osoba zwróciła uwagę na niejasne oznaczenia zbiorów danych na wykresie.

Badani — zapytani, czy czują, że się czegoś nauczyli — we wszystkich przypadkach odpowiadali twierdząco, wskazując na zauważenie nowych aspektów fonologii języka angielskiego i nowe doświadczenie w postaci mówienia izolowanych samogłosek. Kilka osób zaznaczyło, że trwała nauka wymagałaby więcej regularnych ćwiczeń.

Uczestnicy w dużej mierze wykazywali się ciekawością i szybko zdobywali intuicję w kontekście działania interaktywnego wykresu. Niektóre osoby zaznaczyły także, że testy wymowy były dla nich najbardziej stresujące, ponieważ nie były pewne, czy dobrze wymawiają samogłoski. Wiele osób zwróciło też uwagę na trudności w mówieniu samogłosek do aplikacji, zwłaszcza przez dłuższy czas. Niektórzy uczestnicy badania podkreślali, że czuli się niepewnie, mówiąc jedynie samogłoski do komputera, motywując to nienaturalnością takiej sekwencji dźwięków.

Choć aspekt graficzny aplikacji był ogólnie rzecz biorąc doceniany i określany jako “ładny”, niektórzy uczestnicy zgłosili problemy z interfejsem użytkownika. Jedna osoba uznała, że kolory

5.1. WYNIKI PIERWSZYCH DWÓCH ETAPÓW

polskich samogłosek ⟨y⟩ i ⟨e⟩ nie odróżniają się od siebie wystarczająco. Inna osoba uznała, że położenie przycisku aktywującego mikrofon jest nieintuicyjne i, że nie wyróżnia się odpowiednio. Jeszcze inna osoba uznała, że grafika wygląda prototypowo i nie jest wystarczająco profesjonalna.

Najczęściej występującym błędem w aplikacji była nieodpowiednia rejestracja zaokrąglonych samogłosek, a zwłaszcza /u/. Co najmniej 6 osób zwróciło uwagę na ten problem. Najczęściej w tym przypadku drugi formant był bardzo niestabilny. Problem ten był zauważalny już przy kalibracji polskich samogłosek. Część z uczestników była w stanie uzyskać nieprzeciągające się elipsy dopiero po instrukcji, by próbować wymawiać samogłoskę tak, żeby kropka utrzymywała się na ekranie w tym samym miejscu. Poza tym aplikacja nie radziła sobie zupełnie z dużymi różnicami tonu (F_0). Zdarzył się też dwukrotnie krytyczny błąd, który wymagał odświeżenia strony, jednak nie dało się go rzetelnie zreprodukować. Dwa razy został także zgłoszony błąd ze skrótem klawiszowym do kontroli mikrofonu.

Największą uwagę do zbiorów danych były zbyt krótkie nagrania samogłosek polityków. Część osób sugerowała, żeby dodać nagrania amerykańskich ojczystych mówców anglojęzycznych, którzy wymawialiby samogłoski przez dłuższy czas. Niektórzy skarżyli się też na mieszaną jakość nagrań i zbyt małą liczbę przykładowych słów. Dużym problemem było wymawianie samogłosek długo, do czego badani nie byli przyzwyczajeni. Największa trudność leżała jednak w izolowaniu samogłosek i wiele osób przypadkowo wypowiadało całe słowa w teście wymowy zamiast żądanych pojedynczych głosek.

Najbardziej nieintuicyjnym aspektem aplikacji było działanie mikrofonu, który nie wyłączał się po wypowiedzeniu danej samogłoski i od razu rejestrował nagranie do kolejnej. Było to widoczne zwłaszcza w wersji 1.0.0, zanim zostało dodane sprawdzanie swojego nagrania przed przejściem do kolejnego fonemu w testach angielskiej wymowy. Problem ten pozostał jednak w kolejnych wersjach w przypadku rejestracji samogłosek polskich. Prowadziło to do wielu problematycznych sytuacji, gdzie aplikacja rejestrowała niepożądane wycinki mowy jako samogłoski. Wiele osób nie zauważyło też, że na wykresie można kliknąć na konkretny fonem, żeby się na nim skupić, pomimo informacji w legendzie, a później także w instrukcji wideo. Jedna osoba nie zrozumiała, że trafiła do grupy kontrolnej, pomimo, że wyświetlił się jej komunikat z taką informacją. Inna osoba zwróciła uwagę na nieintuicyjną mechanikę pasków postępu.

Część badanych narzekała, że brakuje wizualizacji poprawy w wymowie w miarę ćwiczenia. Niektórzy oczekiwali, że zobaczą wykres ponownie po ukończeniu post-testu. Inna osoba z kolei uznała wręcz przeciwnie, że w aplikacji „łatwo widać progres”. Oprócz tego, pojawiły się uwagi do otwartego charakteru ćwiczenia, które nie dawało wskazówek, co dokładnie trzeba

Kategoria	Przykładowe cytaty uczestników
Aspekty pozytywne	“Wygląda na coś, co się przyda do wymowy.” “Ale to ładnie wszystko wygląda!”
Nabywanie intuicji	“Wracaj w niebieskie, uuu...” “Bardzo dobrze, tam zostaw!” “Trudno mi przesunąć w tej osi język.” “Jasne, przejrzyste, o co chodzi z przestrzenią samogłosek.”
Trudności z wymową	“Dla mnie było problemem, że musisz [samogłoski] utrzymywać długo, nie jestem przyzwyczajony.” “Trudne jest niemówienie, jakby, całego słowa.” “Po prostu muszę beczeć.” “Myślę, że zawsze łatwiej byłoby naśladować, gdyby nagrania były takie, jak ćwiczenia.” “Jest ucięte nagranie, a nie nagranie jak ktoś ćwiczy tę samogłoskę.” “Trudno było samogłoski przeciągać.”
Nagrania polityków	“Te samogłoski są strasznie krótkie.” “Takie krótkie trudno jest naśladować.” “Fajniej by było, gdyby te nagrania głosek były jednak dłuższe.” “Czy przykłady mogłyby być lepsze?”
Problemy z interfejsem	“Problemem jest to, że nie wiem, kiedy mikrofon jest włączony, a kiedy nie.” “Powinno być takie, że dopiero jak odsłuchasz, to możesz puścić [nagrywanie].” “Jak przejdziesz do następnego punktu, to mikrofon zostaje włączony.” “A, to mi będzie odliczać 10 sekund czy mam sama liczyć?”

Tabela 5.4: Przykładowe cytaty uczestników badania z podziałem na kategorie

5.1. WYNIKI PIERWSZYCH DWÓCH ETAPÓW

zrobić w etapie ćwiczenia. Jeden uczestnik nadmienił, że instrukcja jest trochę za długa.

Przykładowe cytaty, które zanotowano w trakcie badania, można zobaczyć w Tabeli 5.4.

5.1.3. Dyskusja

Najcenniejsze informacje, jakie uzyskano w E1&2, to te dotyczące odczuć z korzystania z aplikacji. Niestety największego problemu, jaki zgłaszali uczestnicy — jakości nagrań i długości samogłosek — nie udało się naprawić, gdyż uznano, że przygotowanie nowego zbioru danych będzie zbyt czasochłonne. Rozważano też modyfikację algorytmu, żeby pozwalał uczestnikom na wypowiadanie całych słów — co by było bardziej naturalne — jednak nie było pewności, czy się to powiedzie w wyznaczonych ramach czasowych. Natomiast już w odstępie czasu pomiędzy pierwszym a drugim etapem dodano potwierdzanie każdej samogłoski w testach wymowy amerykańskiej, co znacznie zmniejszyło liczbę niepoprawnych rejestracji w drugim etapie.

Błędna ekstrakcja formantów — jak to miało często miejsce w przypadku /u/ — najprawdopodobniej mogłaby być poprawiona poprzez zastosowanie innej metody niż Burga, na przykład opartej na MFCC. Można by też rozważyć algorytm hybrydowy. Dla tego fonemu występuje sytuacja, że $F_1 \approx F_2$ i dwa formanty mogą “zlewać” się na widmie ze sobą. Jest to szczególnie ważne, gdyż *Samogłoskop* powinien wspierać naukę wymowy w sposób zrozumiały dla ludzi, a nie naukę wymowy w sposób zrozumiały dla aplikacji.

W celu rozwiązania problemu braku wizualnego ukazywania progresu, po drugim etapie dodano do aplikacji możliwość ponownego przetestowania angielskiej wymowy, jeszcze przed przejściem do właściwego post-testu.

Ciekawą obserwacją jest różnica w jakości dźwięku pomiędzy różnymi mikrofonami, jednak warto zwrócić uwagę, że mogła też ona wynikać z różnych środowisk, w których dane modele zostały użyte. Możliwe, że słuchawki *Logitech* były po prostu używane w bardziej hałaśliwych otoczeniach.


Wyniki dotyczące trafności samogłosek nie były konkluzywne. Ponieważ w dużej mierze inspirowano się badaniem [35], postanowiono ponownie się mu przyjrzeć i zwrócić uwagę na największe różnice. Początkowo wydawać by się mogło, że największym problemem jest mała próba badawcza, ale jeśli podliczy się łącznie etapy pierwszy i drugi, wzięło w nich udział więcej osób niż u dr Rehman. Ważnym aspektem jest natomiast, że w jej badaniach osoby ćwiczyły na przestrzeni dziewięciu 30-minutowych sesji, a w tym przypadku była to jedna sesja, bez dolnego limitu czasowego. Pierwsi użytkownicy *Samogłoskopu* sugerowali podobnie, że dłuższa, bardziej regularna nauka byłaby bardziej efektywna.

W związku z tym zdecydowano o przeprowadzeniu trzeciego etapu badań, w którym uczestnicy ćwiczyli przez co najmniej sześć 30-minutowych sesji. Do aplikacji dodano wymóg, że użytkownik musi osiągnąć wyznaczony czas, zanim będzie mógł przejść do testu końcowego.

5.2. Wyniki trzeciego etapu

Typ mikrofonu	Gr. kontrolna	Gr. badawcza	Razem
Wbudowany w laptop	1	1	2
Wbudowany w słuchawki bezprzewodowe	1	3	4
Wbudowany w słuchawki przewodowe	3	1	4
Samodzielny pojemnościowy	1	3	4

Tabela 5.5: Mikrofony używane przez uczestników E3



Rysunek 5.9: Histogram przedstawiający różnice między średnim poziomem mowy a maksymalnym poziomem hałasu w dB dla uczestników E3

Ze względu, że etap trzeci przeprowadzono online, każdy uczestnik korzystał z innego sprzętu. Lista modeli była więc zróżnicowana i zawierała słuchawki przewodowe i bezprzewodowe, a także mikrofony wbudowane w laptopy. Co ciekawe, aż cztery osoby korzystały z samodzielnych mikrofonów pojemnościowych. Podział wszystkich mikrofonów na typy znajduje się w Tabeli 5.5.

Nie zauważono jednak korelacji między typem mikrofonu a jakością rejestracji. Prawdopodobnie największym czynnikiem, jaki na to wpływał, był poziom hałasu w domach uczest-

5.2. WYNIKI TRZECIEGO ETAPU

ników. Na Rysunku 5.9 można zobaczyć histogram wartości Q dla wszystkich badanych. Jak widać, większość osób miała stosunek mowy do największego hałasu na poziomie 20–30 dB, co jest jak najbardziej satysfakcjonującą wartością. Tylko w przypadku trzech osób Q było mniejsze niż 10 dB. Ponownie był jeden przypadek, gdzie wartość ta była ujemna. Natomiast w przeciwieństwie do pierwszych dwóch etapów, dla trzech uczestników poziom jakości był naprawdę wysoki, powyżej 40 dB.

Ponieważ został dodany wymóg, że użytkownik musi przećwiczyć co najmniej 6 dni po 30 minut, rozkład czasu ćwiczenia był znacznie bardziej jednorodny, niż w E1&2. Większość uczestników w grupie badawczej przećwiczyła minimalną wymaganą ilość czasu. Jedna osoba zaczęła dodatkowo ćwiczyć jednego dnia na kwadrans przed północą, co zapisało się jako dodatkowe 15 minut, ale nie liczyło się to jako pełny dzień. Dwie osoby przećwiczyły najwięcej, czyli 7 pełnych dni. W grupie kontrolnej badani nie ćwiczyli pomiędzy testem wstępnym a końcowym.


5.2.1. Trafność samogłosek

Tabela 5.6: Statystyki odległości Mahalanobisa poszczególnych samogłosek w E3


Gr.	Test		i	ɪ	ɛ	æ	ɑ	ʌ	ɔ	ʊ	u	Razem
Kontrolna	Pre-	$\overline{d_M}$	6,62	4,14	3,99	3,00	3,18	3,36	5,35	9,16	6,49	5,03
		σ	4,81	2,30	1,72	1,09	0,54	2,55	3,26	6,80	2,51	3,90
	Post-	$\overline{d_M}$	6,69	7,39	4,92	4,09	3,70	4,33	6,04	8,53	5,19	5,65
		σ	3,81	5,61	2,41	3,20	1,97	2,39	3,60	3,35	1,95	3,67
Badawcza	Pre-	$\overline{d_M}$	4,18	4,69	4,19	4,49	4,12	4,10	3,93	6,36	5,47	4,61
		σ	3,09	0,97	1,68	2,11	1,76	1,57	2,81	3,39	3,62	2,60
	Post-	$\overline{d_M}$	3,42	3,27	3,69	2,50	3,69	2,89	3,00	3,48	1,69	3,07
		σ	2,29	2,09	1,66	1,72	2,85	1,40	2,10	2,49	1,10	2,12

W taki sam sposób jak dla E1&2, policzono średnie odległości Mahalanobisa samogłosek osób badanych w etapie trzecim. Wyniki, z podziałem na fonemy, widnieją w Tabeli 5.6. Jak można zauważyć, w grupie badawczej była zauważalna poprawa dla wszystkich amerykańskich samogłosek. W grupie kontrolnej można z kolei zaobserwować ogólne pogorszenie, z wyjątkiem /ʊ/ i /u/. Średnie wartości znajdują się także na wykresie z Rysunku 5.10. Należy pamiętać, że im mniejsza wartość odległości Mahalanobisa, tym bliższa wymowa do modelowej amerykańskiej. Można zauważyć, że poprawa grupy badawczej jest większa niż pogorszenie grupy kontrolnej.

Porównanie z pierwszymi dwoma etapami pokazuje jednak, że tym razem różnica między



Rysunek 5.10: Średnie odległości Mahalanobisa dla grupy kontrolnej i badawczej w E3



Rysunek 5.11: Wykres pudełkowy przedstawiający zmiany $\log d_M$ w poszczególnych grupach i etapach (im mniejsza wartość, tym lepiej)

5.2. WYNIKI TRZECIEGO ETAPU

grupą badawczą a kontrolną jest znacznie większa. Dla każdego uczestnika badania obliczono jego średnią wartość zmiany odległości w skali logarytmicznej $\overline{\log d_M^{post} - \log d_M^{pre}}$. Na Rysunku 5.11 znajduje się wykres pudełkowy pokazujący je z podziałem na etapy i grupy. W tym przypadku ujemne wartości oznaczają poprawę, a dodatnie pogorszenie. Jak widać, grupa badawcza w etapie trzecim uzyskała znacznie większą poprawę niż grupa badawcza z E1&2. Grupy kontrolne we wszystkich etapach zdają się wykazywać pogorszenie, z pojedynczym wyjątkiem, gdzie osoba w trzecim etapie wykazała znikomą poprawę.

W celu bardziej rygorystycznej analizy, wykonano dopasowanie odległości do liniowego modelu efektów mieszanych. Przyjęto efekty stałe dla grupy (badawcza/kontrolna) i testu (pre-/post-), a efekt losowy dla uczestnika, zgodnie z myślą, że każdy zaczyna z inną trafnością wymowy. Założenie homoskedastyczności nie było spełnione dla odległości samej w sobie — wykres rezydualnej wariancji wobec dopasowanych wartości wykazywał rosnącą zależność wariancji od odległości Mahalanobisa. W związku z tym przeprowadzano transformację logarytmiczną i rozważono model opisany Równaniem (5.2), gdzie i oznacza numer uczestnika, a j numer pomiaru dla danego uczestnika. Zmienna $Grupa_i$ jest równa 0 dla grupy kontrolnej i 1 dla badawczej. Z kolei zmienna $Test_{ij}$ wynosi 1 dla pomiarów z pre-testu, a 0 dla post-testu. Pozostałe wartości są niewiadome: u_i to efekt losowy, niezależny dla każdego badanego, a β_k , $k = 0, 1, 2, 3$ reprezentuje efekty stałe. ϵ_{ij} to błąd pomiaru, który jest niezależny od efektów losowych i stałych.

$$\log d_M^{ij} = \beta_0 + \beta_1 Grupa_i + \beta_2 Test_{ij} + \beta_3 Grupa_i Test_{ij} + u_i + \epsilon_{ij} \quad (5.2)$$

	Wartość	Odchylenie standardowe	p
β_0	0,376	0,056	< 0,0005
β_1	0,284	0,085	0,001
β_2	0,215	0,046	< 0,0005
β_3	-0,268	0,070	< 0,0005
η^2	0,237		

Tabela 5.7: Wyniki dopasowania modelu efektów mieszanych (5.2) w E3


Ponownie skorzystano z biblioteki *statsmodels* w Pythonie, by dopasować model. W przeciwieństwie do E1&2, tym razem wykazał on statystycznie istotne różnice, zarówno pomiędzy grupą kontrolną a badawczą w post teście ($\beta_1 = 0,28$, $\sigma = 0,09$, $p = 0,001$), jak i pomiędzy pre- a post-testem w grupie badawczej ($\beta_2 = 0,22$, $\sigma = 0,05$, $p < 0,0005$). Innymi słowy, model wskazuje na około $10^{0,22} - 1 \approx 66\%$ poprawę odległości w grupie badawczej. Wielkość efektu

została wyliczona w postaci $\eta^2 = 0,24$. Szczegółowe wyniki można znaleźć w Tabeli 5.7.

Dopasowano również zmodyfikowany model, tylko dla danych z grupy kontrolnej:

$$\log d_M^{ij} = \beta_0 + \beta_1 Test_{ij} + u_i + \epsilon_{ij}$$

W tym przypadku nie zauważono statystycznie istotnej zależności ($\beta_1 = -0,054$, $\sigma = 0,051$, $p = 0,30$). Wielkość efektu również była mniejsza i wyniosła $\eta^2 = 0,12$.




Rysunek 5.12: Wykresy punktowe przedstawiające formanty angielskich samogłosek grupy badawczej E3 w pre-tescie (po lewej) i w post-tescie (po prawej). Każdy punkt odpowiada realizacji samogłoski przez jednego uczestnika badania. Duże symbole przedstawiają średnie wartości dla danego fonemu.

Przeprowadzono także analizę z podziałem na poszczególne samogłoski, wyróżniając jedynie pomiary dla grupy badawczej. Na Rysunku 5.12 można zobaczyć wykresy punktowe dla pre- i post-testu. Podobnie jak w widoku aplikacji, pomiary dla pojedynczych badanych oznaczono małymi symbolami, a dużymi — średnią dla całej grupy badawczej. Naniesiono również elipsy niepewności. Jak widać, był znaczący rozrzut pomiędzy badanymi, choć można zaobserwować, że zmniejszył się on w post teście, gdyż elipsy ogólnie są mniejsze i mniej się na siebie nachodzą. Można chociażby zauważyć, że w teście wstępnym /a/ i /u/ przecinały się znacznie ze sobą, a w post teście są już wyraźnie oddzielone. Podobnie można zaobserwować dla pary /æ/ i /ʊ/.

Znowu rozważono zmiany odległości Mahalanobisa w skali logarytmicznej i otrzymano wykres pudełkowy widoczny na Rysunku 5.13. Ponownie, ujemne wartości oznaczają poprawę. Jak widać, jest bardzo duży rozrzut dla wszystkich samogłosek i rozkład każdej z nich przynajmniej “zahacza” wąsem o zero na wykresie. Pokazuje to, że wyniki dla poszczególnych samo-

5.2. WYNIKI TRZECIEGO ETAPU



Rysunek 5.13: Wykres pudełkowy przedstawiający zmiany $\log d_M$ dla poszczególnych samogłosek w grupie badawczej E3 (im mniejsza wartość, tym lepiej)

głosek były mieszane, czasami nawet się pogarszając. Średnio jednak zaobserwować można poprawę i, co zaskakujące, największa jest ona dla /u/. Wyraźna poprawa wystąpiła także dla fonemów /ʊ/, /ɪ/ i /æ/.

Przeprowadzono także dopasowanie modelu efektów mieszanych, ponownie zgodnie z Równaniem (5.2), ale tym razem oddzielnie dla pomiarów każdej samogłoski. W dwóch przypadkach model ten wydawał ostrzeżenia o zbieżności, ale we wszystkich przypadkach ostatecznie zbiegł. Istotność statystyczna była tym mniejsza, im mniejsza poprawa. Wybrane wyniki dla wszystkich fonemów znajdują się w Tabeli 5.8. W celu oszczędności miejsca, zera przed przecinkiem zostały pominięte. Statystycznie znaczące wyniki są pogrubione. Co ciekawe, dla /u/ model podawał ostrzeżenia, mimo że znalezione rozwiązanie cały czas wykazuje największą poprawę dla tego właśnie fonemu i największą wielkość efektu. Wyniki te w dużej mierze zgadzają się z reprezentacją na wcześniejszym wykresie pudełkowym. Najmniejsza różnica związana była z /ε/ i /a/.

Próbowano także przestudiować zależności między poprawą a innymi czynnikami, takimi jak odpowiedzi udzielone w ankiecie, rodzaj mikrofonu, czy jakość poziomów dźwięku Q . Regresja liniowa nie dała jednoznacznych wyników ($R^2 < 0,2$), więc przystąpiono do analizy z użyciem modelu efektów mieszanych, takiego jak w Równaniu (5.2), ale z dodatkowym składnikiem $\beta_4 Zmienna_i$, gdzie $Zmienna_i$ to wartość rozważanej zmiennej dla i -tego uczestnika. Niezależ-

Fonem		i	ɪ	ɛ	æ	ɑ	ʌ	ɔ	ʊ	u
Ostrzeżenia?		Nie	Nie	Nie	Nie	Nie	Tak	Nie	Nie	Tak
β_1	Wartość	,333	,301	,116	,186	,093	,134	,312	,509	,572
	σ	,194	,146	,141	,134	,166	,138	,178	,169	,158
	p	,086	,039	,410	,165	,576	,333	,079	,003	< ,0005
β_2	Wartość	,028	,234	,052	,270	,139	,167	,141	,340	,562
	σ	,115	,071	,117	,093	,136	,128	,117	,128	,146
	p	,810	,001	,654	,004	,306	,190	,227	,008	< ,0005
η^2		,708	,514	,063	,248	,093	,052	,451	,565	,757

Tabela 5.8: Wyniki dopasowania modelu efektów mieszanych (5.2) przy filtrowaniu zbioru danych E3 na poszczególne samogłoski.

nie od wyboru zmiennej nie uzyskano statystycznie istotnych wyników ($p \gg 0,05$). Rozważanie prostszego modelu postaci

$$\log d_M^{ij} = \beta_0 + \beta_1 Zmienna_i + u_i + \epsilon_{ij}$$

na danych z pre-testów we wszystkich etapach również nie przyniosło oczekiwanych rezultatów ($p \gg 0,05$, $\eta^2 < 0.1$). Możliwe, że wymagana jest większa próba badawcza, aby uzyskać bardziej konkluzywne wyniki.

5.2.2. Dyskusja

Przedłużenie badania w trzecim etapie do przynajmniej sześciu półgodzinnych sesji okazało się być dobrą decyzją. Pomimo nawet mniejszej liczby uczestników niż w E1&2, udało się uzyskać wyniki wskazujące, że grupa badawcza poprawiła się w statystycznie istotny sposób po ćwiczeniu w *Samogłoskopie* na przestrzeni kilku dni. Z kolei grupa kontrolna, jak oczekiwano, nie zmieniła się w statystycznie istotny sposób.

Dziwi fakt, że fonem /u/ okazał się być samogłoską o największej poprawie. Jest on bardzo zbliżony do polskiego /u/ i nie spodziewano się, że będzie sprawiał jakiegokolwiek trudności. Warto wziąć jednak pod uwagę, że w pierwszych dwóch etapach to właśnie polskie /u/ było najbardziej problematyczne do identyfikacji przez *Samogłoskop*. Bardzo możliwe, że na trafność wpływał niedoskonały algorytm ekstrakcji formantów i badani nauczyli się mówić tak, żeby ominąć problematyczną rejestrację. Niestety aplikacja nie zapisywała całych nagrań audio, a jedynie dane o formantach uzyskane z algorytmu Burga. Inne samogłoski, dla których odnotowano dużą poprawę, nie występują w języku polskim i łatwo zrozumieć, że użytkownicy

5.2. WYNIKI TRZECIEGO ETAPU

skupiali na nich swoją uwagę.

Należy jednak podkreślić, że badanie to ma pewne niedociągnięcia. Po pierwsze, 14 osób nie jest dużą próbą. Większa liczba uczestników pozwoliłaby na dotarcie do głębszych konkluzji. Badani w tym etapie też byli znacznie mniej zróżnicowani, więc wyciągnięte wnioski niekoniecznie będą się przekładać na inne grupy wiekowe czy społeczne. Problemem była też rezygnacja dwóch osób z trzeciego etapu badania już po przydzieleniu do grupy badawczej. Dobór uczestników nie był losowy, a to ograniczyło go przede wszystkim do osób, które mają większe zainteresowanie nauką wymowy, a zatem są bardziej skłonne do udziału w tego typu badaniu. Ten fakt również może oznaczać, że wyniki te niekoniecznie przełożą się na szerszą populację.

Problemy były zgłaszane też przez samych badanych. Jedna osoba zwróciła uwagę, że kiedy zaczęła ćwiczyć niedługo przed północą, oczekiwała, że czas po północy będzie się nadal liczył do tej samej sesji. Faktycznie, jest to aspekt, który można by w aplikacji poprawić, aby była bardziej przyjazna dla użytkownika. Poza tym, część osób wykonała post-test tego samego dnia, kiedy wykonywali ostatni dzień ćwiczeń, a część była zmuszona przez program do wykonania post-testu bez uprzedniego ćwiczenia tego samego dnia. Nie był to zamierzony efekt i wynikał z niepoprawnego zaprogramowania przechodzenia do testu końcowego.

6. Podsumowanie

Niniejsza praca miała na celu zbadać wpływ aplikacji *Samogłoskop* na wymowę angielskich samogłosek przez osoby polskojęzyczne. Pierwsze dwa etapy badania nie dały statystycznie istotnych wyników ilościowych, ale informacje otrzymane z wywiadów i obserwacji zasugerowały, że może to być interesująca i angażująca forma nauki. Wzięto pod uwagę najważniejsze uwagi i zmodyfikowano zarówno aplikację, jak i sposób prowadzenia badania. Chociaż największy problem — zbyt krótkie nagrania samogłosek — nie został rozwiązany, interfejs zmodyfikowano w celu dania użytkownikowi większej kontroli. Badanie zostało rozszerzone do wielu sesji i znacznie wydłużone.

Wprowadzone zmiany przyniosły oczekiwane rezultaty. Wyniki trzeciego etapu badań wykazały w statystycznie znaczący sposób, że użytkownicy aplikacji w grupie badawczej poprawili swoje umiejętności wymowy angielskich samogłosek. Warto zauważyć, że niektóre z tych zmian były znaczące, a inne nie. Największe zmiany zaobserwowano dla fonemów /u/, /ʊ/, /æ/ i /ɪ/. Grupa kontrolna z kolei pogorszyła się, jednak nie w statystycznie istotny sposób. Pomimo niewielkiej i niezbyt zróżnicowanej próby badawczej oraz niedoskonałego algorytmu ekstrakcji formantów, wyniki pokazują, że wizualizacja przestrzeni samogłosek w czasie rzeczywistym może być skutecznym narzędziem do nauki wymowy angielskich samogłosek przez osoby polskojęzyczne.

6.1. Porównanie z badaniem aplikacji *Vowel Viewer*

Najbardziej zbliżone metodologicznie badanie znajduje się we wspomnianej wcześniej rozprawie doktorskiej Ivany Rehman [35]. Stworzona przez nią aplikacja *Vowel Viewer* również identyfikuje formanty dźwięku i wizualizuje je w czasie rzeczywistym na tle samogłosek modelowych. W badaniu wzięło udział 19 uczestników, którzy korzystali z aplikacji na przestrzeni dziewięciu półgodzinnych sesji.

Otrzymała ona równie znaczącą poprawę w wymowie angielskich samogłosek ($\beta_1 = 0,23$, $p < 0,0001$; $\beta_2 = 0,22$, $p < 0,0001$), jednak ona zastosowała przekształcenie pierwiastkowe

odległości Mahalanobisa zamiast — uznanego przez autora tej pracy za bardziej naturalne — przekształcenia logarytmicznego. Tak czy inaczej, by porównać wyniki, przeprowadzone zostało osobno dopasowanie modelu efektów mieszanych z przekształceniem pierwiastkowym dla danych z badania *Samogłoskopu*. Otrzymano $\beta_1 = 0,610$, $p = 0,003$ oraz $\beta_2 = 0,415$, $p < 0,0005$. Oznacza to, że w tym badaniu poprawa była znacznie większa niż w badaniu dr Rehman. Można to tłumaczyć tym, że w tym badaniu uczestnicy zaczęli ze znacznie większą odległością Mahalanobisa w pre-teście, więc mieli większe pole do poprawy. Być może, gdyby dr Rehman zastosowała przekształcenie logarytmiczne, jej wyniki byłyby bardziej zbliżone do tutaj pokazanych.

Pomimo wielu podobieństw między wspomnianą rozprawą doktorską a niniejszą pracą, należy wspomnieć o licznych różnicach.

- Uczestnicy badania byli studentami Uniwersytetu stanu Iowa, dla których angielski był językiem obcym. Ich poziom zaawansowania był naturalnie znacznie wyższy niż uczestników badania *Samogłoskopu*, gdyż studiowali oni w języku angielskim i komunikowali się nim na co dzień. Ich języki ojczyste były zróżnicowane, choć w większości były to języki azjatyckie. Ani jedna osoba w badaniu z *Vowel Viewerem* nie reprezentowała słowiańskiej rodziny języków. Tutaj uczestnicy byli osobami polskojęzycznymi, które mieszkały w Polsce. Wyjaśnia to po części różnice w średniej odległości Mahalanobisa w pre-teście, która była na poziomie 1,7 w badaniu dr Rehman, a powyżej 4,5 w niniejszym badaniu. Może to też tłumaczyć różnice w tym, które fonemy się najbardziej poprawiły.
- W badaniu *Samogłoskopu* użytkownicy w grupie kontrolnej w trzecim etapie nie korzystali w ogóle z aplikacji pomiędzy pre- a post-testem. W badaniu dr Rehman grupa kontrolna korzystała z aplikacji, ale ćwiczyła jedynie na podstawie listy słów i nagrań wideo, bez wizualizacji formantów. Badaczka wykazała, że aspekt wizualizacji jest kluczowy dla poprawy wymowy.
- W badaniu opartym na *Vowel Viewerze* rejestrowany był głos uczestników, a formanty były wyodrębniane później, ręcznie przez badaczkę. W aktualnej pracy formanty były wyodrębniane w czasie rzeczywistym przez aplikację, co najprawdopodobniej wprowadziło dodatkowe błędy pomiarów. Może to być inne wytłumaczenie, dlaczego średnia odległość Mahalanobisa w tym badaniu była znacznie wyższa niż u dr Rehman.
- Przedstawione tutaj badanie w trzecim etapie było przeprowadzone w całości w formie zdalnej, co miało swoje zalety i wady. Uczestnicy mogli korzystać z aplikacji w dowolnym miejscu, co zwiększyło ich komfort. Z drugiej strony, nie można było kontrolować warun-

ków nagrywania, co mogło wpłynąć na jakość nagrań. W badaniu dr Rehman uczestnicy korzystali z aplikacji w laboratorium, co zapewniało lepszą kontrolę nad warunkami nagrywania.

- W obecnym badaniu uczestnicy byli zmuszeni do wypowiadania samogłosek w izolacji, co niekoniecznie musi się przekładać na poprawną wymowę w naturalnej mowie. W badaniu dr Rehman uczestnicy ćwiczyli wymowę w kontekście całych słów, co może być bardziej efektywne w nauce wymowy. Poza tym testy wymowy przeprowadzone przez badaczkę były bardziej rozbudowane i zawierały więcej nagrań, niż po jednym na samogłoskę, jak to miało miejsce w *Samogłoskopie*.
- Wspomniana rozprawa doktorska zawierała także aspekt testowania wymowy na nowych słowach, które nie były ćwiczone w aplikacji. Poza tym pojawił się też aspekt narracji wideo, gdzie badani mogli wypowiadać się w bardziej spontaniczny sposób. Ivana Rehman zauważyła, że poprawa występuje też w przypadku nowych słów, ale w przypadku narracji pojawiła się dopiero w opóźnionym post-teście.
- Wymowa studentów ze stanu Iowa była również oceniana przez fonetyków pod kątem zrozumiałości, co nie miało miejsca w badaniu *Samogłoskopu*. Wyniki oceny fonetyków były zgodne z analizą formantów, co sugeruje, że tego typu pomiar akustyczny w dużej mierze przekłada się na percepcję fonetyczną.
- Dr Rehman nie przeprowadziła normalizacji danych o formantach, co mogło wpłynąć na czytelność wykresu w jej aplikacji, a także, naturalnie, zaburzyło odległości Mahalanobisa. Jej program nie był kalibrowany do głosu konkretnych uczestników i nie brał pod uwagę różnic w rozmiarach aparatu wymowy, które najpewniej są kluczowe dla wizualizacji formantów. *Samogłoskop* stosuje normalizację danych, co pozwoliło na uzyskanie bardziej czytelnych wykresów, z wyraźnymi granicami między fonemami.
- Modelowe dane w *Vowel Viewerze* pochodziły z nagrań głosu przeprowadzonych przez badaczkę i były tym samym bardziej aktualne. Językoznawczynie zdecydowała się również na pominięcie fonemu /ɔ/, ze względu na zjawisko “cot”-“caught” merger, więc rozważała o jeden fonem mniej. Może to tłumaczyć, dlaczego *Samogłoskop* używa danych Peterson & Barney, które są starsze i być może z tego powodu odległości Mahalanobisa osiągnięte przez nagrania polityków były na poziomie 2,5, co jest znacznie powyżej 1,7, odległości Mahalanobisa uczestników badania dr Rehman w pre-teście. W tym przypadku można by się zastanowić, czy nie lepiej byłoby użyć danych z nowszych badań.

6.2. DALSZY ROZWÓJ

- W badaniu ze stanu Iowa uczestnicy wykazali największą poprawę w wymowie fonemu /ɑ/, co stoi w zupełnym przeciwieństwie do tej pracy, w której ta samogłoska wykazała drugą najmniejszą poprawę. Jak jednak wspomniano wyżej, w badaniu dr Rehman fonem /ɑ/ stanowi połączenie fonemów /ɔ/ i /ɑ/ wydzielonych w *Samogłoskopie*, co może tłumaczyć różnice w wynikach.
- *Samogłoskop* jest dostępny jako aplikacja webowa, co oznacza, że można z niej korzystać na różnych urządzeniach, w tym mobilnych, bez potrzeby instalacji. Dodatkowo, program ten posiada bardziej rozbudowany interfejs użytkownika, który pozwala na większą kontrolę nad nagraniami i wizualizacją formantów. Prawdopodobnie jest to jego największa przewaga nad *Vowel Viewerem*.

6.2. Dalszy rozwój

Stworzona aplikacja *Samogłoskop* — i ogólnie wizualizacja formantów w czasie rzeczywistym — wykazuje duży potencjał do rozwoju. Przede wszystkim warto rozważyć dodanie nagrań modelowych izolowanych samogłosek do aplikacji, co ułatwiłoby ich naśladowanie. Dodanie automatycznego rozpoznawania granic fonemów byłoby idealne, ponieważ wtedy użytkownik mógłby wypowiadać całe słowa, co byłoby bardziej naturalne. Nawet, jeśli ograniczyć się tylko do względnie neutralnych kontekstów fonetycznych, takich jak /hVd/, to i tak mogłoby to pomóc użytkownikom z największą do tej pory trudnością. Głębsze uwzględnienie kontekstu pod względem tego, jak dokładnie poszczególne otaczające spółgłoski wpływają na formanty, mogłoby otworzyć jeszcze szersze pole możliwości. Tak czy inaczej, kwestia nienaturalności izolowania samogłosek powinna zostać zaadresowana.

Innym ważnym aspektem programu jest sam algorytm ekstrakcji formantów, który w tym momencie nie radzi sobie dobrze z tylnymi zaokrąglonymi samogłoskami, takimi jak /ɔ/ i /u/. Metoda Burga oparta na analizie LPC nie jest w tym przypadku najlepszym rozwiązaniem. Warto rozważyć algorytmy oparte na analizie MFCC, bayesowskie, sieci neuronowe, jak te rozważane na początku Rozdziału 2, albo połączyć je w metodę hybrydową. Trzeba jednak pamiętać, żeby nie robić tego kosztem wydajności, ponieważ aplikacja musi działać w czasie rzeczywistym.

Zdecydowanie cennym kierunkiem rozwoju byłoby również uwzględnienie innych języków i dialektów. W teorii aplikację można dostosować do dowolnego języka, pod warunkiem, że dostępne są odpowiednie dane modelowe. Trzeba jednak pamiętać, że w tym momencie aplikacja nie uwzględnia rotyczności czy nosowości, co może być istotnym aspektem w niektórych języ-

kach. Wykorzystanie danych z dotychczasowych badań na temat akustyki tych zjawisk pozwoliłoby, chociażby, na dodanie trzeciego wymiaru do wizualizacji, jeśli to potrzebne. Uwzględnienie dyftongów i wizualizacja ich w postaci krzywych również mogłaby poszerzyć dydaktyczną rolę aplikacji.

Praktyczność zawarcia tego typu aplikacji w metodach nauczania języków obcych cały czas jawi się dość niepewnie. Warto rozważyć przeprowadzenie badań z większą próbą badawczą, aby uzyskać bardziej wiarygodne wyniki. Większa grupa pozwoliłaby m.in. na lepsze przestudiowanie różnic w poprawie pomiędzy fonemami. Należy również zadbać o większe zróżnicowanie uczestników pod względem płci, wieku, wykształcenia, poziomu znajomości języka angielskiego oraz innych czynników. Można również wziąć pod uwagę zastosowanie aplikacji w szerszym kontekście, takich jak nauka języków obcych w szkole czy kursie językowym na przestrzeni miesięcy. W szczególności interesującym aspektem byłoby przeprowadzenie badań z udziałem dzieci, lub osób z zaburzeniami mowy. Ciekawi też, jak osoby mniej obyte z komputerami poradziłyby sobie z aplikacją.

Bibliografia

- [1] Patti Adank, Roel Smits i Roeland Van Hout. „A comparison of vowel normalization procedures for language variation research”. W: *The Journal of the acoustical society of America* 116.5 (2004), s. 3099–3107.
- [2] International Phonetic Association. *Handbook of the International Phonetic Association: A guide to the use of the International Phonetic Alphabet*. Cambridge University Press, 1999.
- [3] Michael Berger. „Measurement of vowel nasalization by multi-dimensional acoustic analysis”. Prac. mag. University of Rochester. Department of Linguistics, 2007.
- [4] Paul Boersma i Vincent Van Heuven. „Speak and unSpeak with PRAAT”. W: *Glott International* 5.9/10 (2001), s. 341–347.
- [5] BoldVoice. *BoldVoice / American Accent Training App*. <https://boldvoice.com>. Data dostępu: 2025-04-20.
- [6] Mara Carvalho i Aníbal Ferreira. „Real-time recognition of isolated vowels”. W: *International Tutorial and Research Workshop on Perception and Interactive Technologies for Speech-Based Systems*. Springer. 2008, s. 156–167.
- [7] Bertha Chela-Flores. „Pronunciation and language learning: An integrative approach”. W: *International Review of Applied Linguistics in Language Teaching* 39.2 (2001), s. 85–101.
- [8] Irving B Crandall. „The sounds of speech”. W: *The bell system technical journal* 4.4 (1925), s. 586–639.
- [9] Sandra Ferrari Disner. „Evaluation of vowel normalization procedures”. W: *The Journal of the Acoustical Society of America* 67.1 (1980), s. 253–261.
- [10] Keelan Evanini, Stephen Isard i Mark Liberman. „Automatic formant extraction for sociolinguistic analysis of large corpora.” W: *Interspeech*. 2009, s. 1655–1658.
- [11] Gunnar Fant. „Acoustic Theory of Speech Production”. W: 2 wyd. The Hague: Mouton, 1970. Rozd. 1.11, s. 15–21.

- [12] Aníbal JS Ferreira. „Static features in real-time recognition of isolated vowels at high pitch”. W: *The Journal of the Acoustical Society of America* 122.4 (2007), s. 2389–2404.
- [13] Nicholas Flynn. „Comparing vowel formant normalisation procedures”. W: *York Papers in Linguistics Series* 2.11 (2011), s. 1–28.
- [14] James W Forgie i Carma D Forgie. „Results obtained from a vowel recognition computer program”. W: *The Journal of the Acoustical Society of America* 31.11 (1959), s. 1480–1489.
- [15] Harald Frostel, Andreas Arzt i Gerhard Widmer. „The vowel worm: Real-time mapping and visualisation of sung vowels in music”. W: *Proceedings of the 8th Sound and Music Computing Conference*. Citeseer. 2011, s. 214–219.
- [16] A Gray i D Wong. „The Burg algorithm for LPC Speech analysis/synthesis”. W: *IEEE Transactions on Acoustics, Speech, and Signal Processing* 28.6 (1980), s. 609–615.
- [17] James Hillenbrand i in. „Acoustic characteristics of American English vowels”. W: *The Journal of the Acoustical society of America* 97.5 (1995), s. 3099–3111.
- [18] James M Hillenbrand, Michael J Clark i Terrance M Nearey. „Effects of consonant environment on vowel formant patterns”. W: *The Journal of the Acoustical Society of America* 109.2 (2001), s. 748–763.
- [19] Duolingo Inc. *Duolingo - The world's best way to learn a language*. <https://www.duolingo.com>. Data dostępu: 2025-04-20.
- [20] Yannick Jadoul, Bill Thompson i Bart De Boer. „Introducing parselmouth: A python interface to praat”. W: *Journal of Phonetics* 71 (2018), s. 1–15.
- [21] W Jassem. „Acoustic-phonetic variability of polish vowels”. W: *Archives of Acoustics* 17.2 (2014), s. 217–233.
- [22] Wiktor Jassem. „A phonologic and acoustic classification of Polish vowels”. W: *STUF-Language Typology and Universals* 11.1-4 (1958), s. 299–319.
- [23] Daniel Jones. *An English Pronouncing Dictionary: containing 54902 words in international phonetic transcription*. 6 wyd. J. M. Dent & Sons Ltd, 1944.
- [24] Daniel Kahn. „Near-perfect identification of speaker-randomized vowels without consonantal transitions”. W: *The Journal of the Acoustical Society of America* 62.S1 (1977), S101–S101.
- [25] Raymond D Kent i Houri K Vorperian. „Static measurements of vowel formant frequencies and bandwidths: A review”. W: *Journal of communication disorders* 74 (2018), s. 74–97.

- [26] William Labov, Sharon Ash i Charles Boberg. „The North American English vowel system”. W: *The atlas of North American English: Phonetics, phonology and sound change*. Mouton de Gruyter, 2006. Rozd. 2, s. 11–15.
- [27] Xinjian Li i in. „Universal phone recognition with a multilingual allophone system”. W: *ICASSP 2020-2020 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. IEEE. 2020, s. 8249–8253.
- [28] Björn EF Lindblom i Michael Studdert-Kennedy. „On the role of formant transitions in vowel recognition”. W: *The Journal of the Acoustical society of America* 42.4 (1967), s. 830–843.
- [29] Boris M Lobanov. „Classification of Russian vowels spoken by different speakers”. W: *The Journal of the Acoustical Society of America* 49.2B (1971), s. 606–608.
- [30] Ken Lodge. „A critical introduction to phonetics”. W: Bloomsbury Publishing, 2009, s. 87.
- [31] Geoffrey Stewart Morrison i Peter F. Assmann, red. *Vowel Inherent Spectral Change*. Springer, 2013.
- [32] Yulia Oganian i in. „Vowel and formant representation in the human auditory speech cortex”. W: *Neuron* 111.13 (2023), s. 2105–2118.
- [33] Gordon E Peterson i Harold L Barney. „Control methods used in a study of the vowels”. W: *The Journal of the acoustical society of America* 24.2 (1952), s. 175–184.
- [34] Sravana Reddy i James N Stanford. „Toward completely automated vowel extraction: Introducing DARLA”. W: *Linguistics Vanguard* 1.1 (2015), s. 15–28.
- [35] Ivana Rehman. „Real-time formant extraction for second language vowel production training”. Prac. dokt. Iowa State University, 2021.
- [36] Bronisław Ročławski. *Zarys fonologii, fonetyki, fonotaktyki i fonostatystyki współczesnego języka polskiego*. Wydawnictwo Uczelniane Uniwersytetu Gdańskiego, 1976.
- [37] Arkadiusz Rojczyk. „Quality and duration of unstressed vowels in Polish”. W: *Lingua* 217 (2019), s. 80–89.
- [38] Ronald W Schafer i Lawrence R Rabiner. „System for automatic formant analysis of voiced speech”. W: *The Journal of the Acoustical Society of America* 47.2B (1970), s. 634–648.

- [39] UCL Division of Psychology Speech Hearing & Phonetic Sciences i Language Sciences. *Available Datasets - PALS0039 Introduction to Deep Learning for Speech and Language Processing*. <https://www.phon.ucl.ac.uk/courses/pals0039/datasets.php>. Data dostępu: 2025-04-10. Wrz. 2022.
- [40] *VowelViz Pro on the App Store*. <https://apps.apple.com/us/app/vowelviz-pro/id835534002>. Data dostępu: 2025-01-26.
- [41] Jun Wang i in. „Vowel recognition from articulatory position time-series data”. W: *2009 3rd International Conference on Signal Processing and Communication Systems*. IEEE. 2009, s. 1–6.
- [42] JG Wells. „A study of the formants of the pure vowels of British English”. Prac. mag. University of London London, UK, 1962.
- [43] John Christopher Wells. „GenAm revisited”. W: *Beyond the British Isles*. T. 3. Accents of English. Cambridge University Press, 1982. Rozd. 6.1, s. 467–489.
- [44] Andrew Matthew Zimmer. „VATA: An improved personal computer-based vowel articulation training aid”. Prac. mag. Old Dominion University, 2002.

Wykaz symboli i skrótów

/ /	Transkrypcja fonologiczna, patrz Podrozdział 1.1
[]	Transkrypcja fonetyczna (szczegółowa), patrz Podrozdział 1.1
< >	Zapis ortograficzny, patrz Podrozdział 1.1
d_M	Odległość Mahalanobisa
η^2	Wielkość efektu, stosunek wariancji wyjaśnionej do całkowitej
F_0	Częstotliwość podstawowa głosu
F_i	Częstotliwość i -tego formantu, $i = 1, 2, \dots$
L_m	Poziom natężenia dźwięku <i>mowy</i> zarejestrowany podczas kalibracji
L_o	Poziom natężenia dźwięku <i>otoczenia</i> zarejestrowany podczas kalibracji
log	Logarytm dziesiętny
p	Prawdopodobieństwo testowe (tzw. p-value)
Q	Poziom jakości rejestracji, patrz Równanie (5.1)
σ	Odchylenie standardowe
$\bar{x}$	Średnia arytmetyczna z x
E1&2	Etapy pierwszy i drugi badania
E3	Etap trzeci badania
IPA	Międzynarodowy alfabet fonetyczny (ang. International Phonetic Alphabet)
MFCC	Współczynniki cepstralne oparte na skali mel (ang. Mel-frequency cepstral coefficients)
LPC	Predykcja liniowa (ang. Linear Predictive Coding)

Spis rysunków

1.1	Trapezowa reprezentacja przestrzeni samogłosek	11
1.2	U góry: spektrogram samogłoski /ae/ w angielskim słowie <i>and</i> wypowiedzianym przez Donalda Trumpa z zaznaczonymi pierwszymi dwoma formantami. U dołu: Wartości F_1 i F_2 z powyższego słowa przedstawione razem z pomiarami innych samogłosek tego samego mówcy.	14
1.3	Proces przetwarzania samogłosek	16
3.1	Zrzut ekranu po pierwszym uruchomieniu aplikacji	26
3.2	Zrzut ekranu z wyborem kategorii głosu	26
3.3	Zrzut ekranu w trakcie kalibracji poziomów	27
3.4	Zrzut ekranu w trakcie nagrywania polskich samogłosek	28
3.5	Zrzut ekranu z zatwierdzeniem polskich samogłosek	28
3.6	Zrzuty ekranu przedstawiające kolejno centroid, chmurę punktów i elipsę dla samogłoski /i/	29
3.7	Prezentacja błędnego rysowania elips	30
3.8	Zrzut ekranu testu angielskiej wymowy	30
3.9	Zrzut ekranu domyślnego widoku ćwiczenia	32
3.10	Zrzut ekranu reprezentujący zbiór danych Peterson & Barney	32
3.11	Zrzut ekranu reprezentujący pomiary formantów polityków	33
3.12	Zrzut ekranu widoku ćwiczenia angielskiego /u/	34
3.13	Zrzut ekranu reprezentujący widok ustawień	35
3.14	Zrzut ekranu w orientacji pionowej	36
5.1	Bąbelkowy wykres przedstawiający znajomość angielskiego i amerykańskiej wymowy	52
5.2	Histogram przedstawiający znajomość symboli fonetycznych	52
5.3	Histogram przedstawiający liczbę języków obcych, które znali uczestnicy badania	53
5.4	Wykres przedstawiający środki przestrzeni samogłosek z podziałem na płeć	54

5.5	Wykres punktowy przedstawiający formanty polskich samogłosek	54
5.6	Histogram czasu ćwiczenia w E1&2	55
5.7	Wykresy pudełkowe przedstawiające bezwzględne poziomy głośności dla obu modeli słuchawek w E1&2	56
5.8	Wykres pudełkowy przedstawiający Q dla E1&2	56
5.9	Histogram przedstawiający Q w E3	62
5.10	Średnie odległości Mahalanobisa w E3	64
5.11	Wykres pudełkowy przedstawiający zmiany $\log d_M$ w poszczególnych grupach i etapach	64
5.12	Wykresy punktowe przedstawiające formanty angielskich samogłosek grupy badawczej w E3	66
5.13	Wykres pudełkowy przedstawiający zmiany $\log d_M$ dla poszczególnych samogłosek w grupie badawczej E3	67

Spis tabel

3.1	Kategorie głosu	26
3.2	Style reprezentacji zbiorów danych	33
3.3	Samogłoski polskie	38
3.4	Samogłoski angielskie	38
3.5	Podział fragmentów nagrań	42
4.1	Etapy badania	46
4.2	Odległości Mahalanobisa Amerykanów	47
5.1	Demografia uczestników badania	50
5.2	Statystyki dla pytań o odpowiedziach całkowitoliczbowych	51
5.3	Statystyki odległości Mahalanobisa w E1&2	57
5.4	Przykładowe cytaty uczestników badania	60
5.5	Mikrofony używane przez uczestników E3	62
5.6	Statystyki odległości Mahalanobisa w E3	63
5.7	Wyniki modelu mieszanego w E3	65
5.8	Wyniki modelu mieszanego z podziałem na fonemy w E3	68

Spis załączników

1. Lista słów zawartych w aplikacji
2. Lista wyrażeń zawartych w aplikacji

Załącznik 1. Lista słów zawartych w aplikacji

W transkrypcjach słów pogrubiono samogłoski, z którymi były powiązane w aplikacji. Niektóre słowa powiązane były z więcej niż jedną samogłoską. Dla przykładu, słowo *already* /ɔlɹɛdi/ było podane jako przykład zarówno dla fonemu /ɔ/ jak i /i/.

Słowa z nagraniami polityków

Słowo	Transkrypcja	Tłumaczenie	Liczba nagrań
the	/ði/	[przedimek określony]	2
already	/ɔlɹɛdi/	już	1
Indiana	/ɪndiæne/	Indiana (stan w USA)	1
steal	/stil/	kraść, ukraść	1
strongly	/stɔŋli/	mocno	1
me	/mi/	mnie	1
Wisconsin	/wɪskɑnsɪn/	Wisconsin (stan w USA)	1
if	/ɪf/	jeśli	1
win	/wɪn/	wygrać	1
women	/wɪmɪn/	kobiety	1
them	/ðɛm/	nich, ich	1
guests	/gɛsts/	goście	1
aspect	/æspɛkt/	aspekt	1
and	/ænd/	i	1
as	/æz/	jako	1
lot	/lɑt/	dużo, mnóstwo	2
on	/ɑn/	w (dosł. na)	1
job	/dʒɑb/	praca	1
won	/wʌn/	wygrał	1
from	/frʌm/	od	1

Załącznik 1. Lista słów zawartych w aplikacji

Słowo	Transkrypcja	Tłumaczenie	Liczba nagrań
us	/ʌs/	nas	1
much	/mʌtʃ/	bardzo	1
come	/kʌm/	przychodzić	1
of	/ʌv/	z, od, o	1
brought	/brɔt/	doprowadziło	1
water	/wɔrə/	woda	1
put	/pʊt/	umieścić	1
good	/gʊd/	dobry	1
neighborhoods	/neɪbəʰʊdz/	sąsiedztwa	1
to	/tu/	aby	2
Gertrude	/gɜːtuːd/	Gertruda (imię)	1
few	/fju/	kilka	1

Słowa bez nagrań

Słowo	Transkrypcja	Tłumaczenie
sheep	/ʃip/	owca, owce
sheet	/ʃit/	prześcieradło, arkusz
beach	/bitʃ/	plaża
be	/bi/	być
ship	/ʃip/	statek
in	/ɪn/	w, we
is	/ɪz/	jest
with	/wɪð/	z, ze
his	/hɪz/	jego
bed	/bed/	łóżko
many	/meni/	wiele
said	/sed/	powiedział
red	/ɹed/	czerwony
pen	/pen/	długopis
head	/hed/	głowa
bat	/bæt/	nietoperz, kij
bad	/bæd/	zły, zła

SŁOWA BEZ NAGRAŃ

Słowo	Transkrypcja	Tłumaczenie
that	/ðæt/	ten, tamten
at	/æt/	przy, w
have	/hæv/	mieć
can	/kæn/	móc, puszka
not	/nɒt/	nie
sock	/sɒk/	skarpetka
bomb	/bʌm/	bomba
bot	/bɒt/	bot
palm	/pʌm/	dłoń, palma
father	/fɑðə/	ojciec
but	/bʌt/	ale
one	/wʌn/	jeden
other	/ʌðə/	inny, drugi
some	/sʌm/	trochę, niektóre
son	/sʌn/	syn
also	/ɔlsoʊ/	również
all	/ɔl/	wszystko, całe
law	/lɔ/	prawo
saw	/sɔ/	piła, widział
thought	/θɔt/	myśl, myślał
boss	/bɒs/	szef
pull	/pʊl/	ciągnąć
would	/wʊd/	by
could	/kʊd/	mógł
should	/ʃʊd/	powinien
wood	/wʊd/	drewno
foot	/fʊt/	stopa
book	/bʊk/	książka
pool	/puːl/	basen, bilard
use	/juːz/	używać
goose	/guːs/	gęś
food	/fuːd/	jedzenie
blue	/bluː/	niebieski

Załącznik 1. Lista słów zawartych w aplikacji

Słowo	Transkrypcja	Tłumaczenie
shoe	/ʃu/	but
who	/hu/	kto

Załącznik 2. Lista wyrażen zawartych w aplikacji

Podkreślono słowa z Załącznika 1, z którymi powiązane są wyrażenia.

Wyrażenia wycięte z przemówienia Donalda Trumpa

Wyrażenie	Tłumaczenie
... <u>the</u> legal votes,	... legalne głosy,
I've <u>already</u>	Ja już
Iowa, <u>Indiana</u> , Ohio	Iowa, Indiana, Ohio (stany w USA)
They can try to <u>steal</u>	Mogą próbować ukraść
We're looking to <u>them</u> very <u>strongly</u>	Bardzo mocno na nich liczymy
"Biden up 17 points in <u>Wisconsin</u> "	"Biden z przewagą 17 punktów w Wisconsin"
<u>If</u> you count. . .	Jeśli policzyć. . . (dosłownie: Jeśli policzysz. . .)
I easily <u>win</u>	z łatwością wygrywam
<u>And</u> it's been properly acknowledged	I zostało to odpowiednio uznane
by a <u>lot</u>	o wiele, znacznie
decisively <u>won</u>	decydująco wygrałem
the election <u>from us</u>	wybory od nas
get the observers <u>put</u> in	umieścić obserwatorów (dosł. sprawić, żeby obserwatorzy zostali umieszczeni)
That doesn't do us any <u>good</u> .	Nie pomaga nam to w niczym. (dosł. To nie robi nam nic dobrego.)
I'd like <u>to</u> . . .	Chciałbym. . .
To name just a <u>few</u> ,	żeby wymienić tylko kilka,

Wyrażenia wycięte z przemówienia Hillary Clinton

Wyrażenie	Tłumaczenie
<u>the</u> Secretary General	Sekretarz Generalny
for inviting <u>me</u>	za zaproszenie mnie
<u>women</u> make	kobiety tworzą
distinguished delegates and <u>guests</u>	dystyngowani delegaci i goście
in every <u>aspect</u>	w każdym aspekcie
<u>As</u> mothers,	Jako matki,
<u>on</u> the <u>job</u>	w pracy
Thank you very <u>much</u>	Dziękuję Wam bardzo
We <u>come</u> together	Zbieramy się (dosł. Przychodzimy razem)
<u>of</u> life.	życia.
that has <u>brought</u> us to this point	co nas doprowadziło do tego punktu
<u>water</u> cooler	dystrybutor wody (dosł. schładzacz wody)
homes, <u>neighborhoods</u> and workplaces	domy, sąsiedztwa i miejsca pracy
I would like <u>to</u>	Chciałabym
<u>Gertrude</u> , Mangela	Gertrudo, Mangelo

Wyrażenia bez nagrań

Wyrażenie	Tłumaczenie
The <u>sheep</u> graze in the distance	Owce wypasają się w oddali
a <u>sheet</u> of paper	kartka papieru
a sandy <u>beach</u>	piaszczysta plaża
I will <u>be</u> there	Będę tam
a <u>ship</u> captain	kapitan statku
I am <u>in</u> the room	Jestem w pokoju
He <u>is</u> a good man	On jest dobrym człowiekiem
I am <u>with</u> my friends	Jestem z moimi przyjaciółmi
<u>His</u> name is John	Jego imię to John
a double <u>bed</u>	podwójne łóżko
I have <u>many</u> friends	Mam wielu przyjaciół
He <u>said</u> he will go	On powiedział, że pójdzie

WYRAŻENIA BEZ NAGRAŃ

Wyrażenie	Tłumaczenie
I like <u>red</u>	Lubię czerwony
I need a <u>pen</u>	Potrzebuję długopisu
a baseball <u>bat</u>	kij do baseballa
a <u>bad</u> person	zły człowiek
<u>that</u> is a good idea	to dobry pomysł
I am <u>at</u> home	Jestem w domu
I <u>have</u> a car	Mam samochód
I <u>can</u> do it	Mogę to zrobić
I am <u>not</u> going	Nie idę
I need a new <u>sock</u>	Potrzebuję nowej skarpetki
The <u>bomb</u> exploded	Bomba wybuchła
Am I talking to a <u>bot</u> ?	Czy rozmawiam z botem?
The coconut grows on <u>palm</u> trees	Kokos rośnie na palmach
I am tired <u>but</u> I will go	Jestem zmęczony, ale pójde
<u>one</u> , two, three	jeden, dwa, trzy
the <u>other</u> side	druga strona
I have <u>some</u> money	Mam trochę pieniędzy
I am <u>also</u> going	Też idę
<u>all</u> the time	cały czas
the <u>law</u> of the land	prawo ziemi
I <u>saw</u> a tree	Widziałem drzewo
I had a <u>thought</u>	Miałem myśl
I will <u>pull</u> the rope	Pociągnę za linę
I <u>would</u> like to go	Chciałbym iść
I <u>could</u> do it	Mógłbym to zrobić
I <u>should</u> go	Powinienem iść
a piece of <u>wood</u>	kawałek drewna
I hurt my <u>foot</u>	Zraniłem swoją stopę
I read a <u>book</u>	Przeczytałem książkę
a swimming <u>pool</u>	basen do pływania
I will <u>use</u> it	Użyję tego
A <u>goose</u> is a bird	Gęś to ptak
I am hungry, I need <u>food</u>	Jestem głodny, potrzebuję jedzenia

Załącznik 2. Lista słów zawartych w aplikacji

Wyrażenie	Tłumaczenie
The sky is <u>blue</u>	Niebo jest niebieskie
I need a new <u>shoe</u>	Potrzebuję nowego buta
<u>Who</u> is there?	Kto tam jest?